Inteligencia Artificial: Trabajo práctico 2

Ph. D. Saúl Calderón Ramírez
Instituto Tecnológico de Costa Rica,
Escuela de Ingeniería en Computación, Programa de Ciencias de Datos,
PAttern Recongition and MAchine Learning Group (PARMA-Group)

29 de septiembre de 2026

Fecha de entrega: Martes 20 de Octubre.
Entrega: Un archivo .zip con el código fuente LaTeX o Lyx, el pdf, y un notebook Jupyter, debidamente documentado. A través del TEC-digital.
Modo de trabajo: Grupos de 3 personas.

Resumen

En el presente trabajo práctico se introducira el desarrollo y uso de modelos de clasificacion lineal y no supervisados para resolver un problema práctico en ciberseguridad.

En el presente trabajo practico se utilizara el *dataset SMSSpamCollection* disponible en `https://archive.ics.uci.edu/dataset/228/sms+spam+collection`, el cual consiste en un conjunto público de mensajes SMS etiquetados que se han recopilado para la investigación del spam en teléfonos móviles en Reino Unido.

1. (60 puntos) Aprendizaje Supervisado: Regresión Logística

1. **(10 puntos)** Implemente la evaluación de un modelo de regresión logística en la función *forward* en pytorch.

   a) Diseñe al menos 2 pruebas unitarias para esta función.

2. **(10 puntos)** Implemente el entrenamiento del modelo de regresión logística en la función *train_logistic_regression* en *pytorch.*

   a) Diseñe al menos 2 pruebas unitarias para esta función.

3. **(10 puntos)** Genere un conjunto de datos linealmente separable en 2 dimensiones, y verifique el funcionamiento del regresor logistico. Realice los graficos y tablas necesarios para ilustrar el proceso.

4. **(10 puntos)** Implemente la extracción de características con el codificador y particione los datos en 70 % de entrenamiento y 30 % de prueba, y corra el entrenamiento y prueba 30 veces. Reporte los resultados de forma clara y comentelos. Utilice las metricas de tasa de aciertos y F1-score.

5. **(20 puntos)** Realice la reducción de dimensionalidad en 50 %, 25 % y a 2 dimensiones usando un análisis de componentes principales. Grafique todo el conjunto de datos en las dimensiones y analice los resultados de realizar la clasificacion con el modelo de regresion logistica.

2. (30 puntos) Detección de Anomalías: Umbral de Verosimilitud

1. **(20 puntos)** Implemente la estimación de las densidades usando un conjunto de datos de entrenamiento X_{train}, utilizando un histograma para estimar cada una de la dimensiones $p_1, p_2, p_3, \ldots, p_D$. Use la cantidad de dimensiones D optima deducida en el apartado anterior. Grafique las densidades y comentelas haciendo. Defina un umbral que tome en cuenta el puntaje de las verosimilitudes sumadas para todas las densidades, para seleccionar los datos fuera de la distribución.

2. **(10 puntos)** Particione los datos en 70 % de entrenamiento y 30 % de prueba, y corra el entrenamiento (construcciones de densidades) 30 veces. Reporte los resultados de forma clara y comentelos, con respecto a los resultados anteriores. Utilice las metricas de tasa de aciertos y F1-score.

3. (10 puntos) Clasificación supervisada: Modelos Grandes de Lenguaje

1. **(10 puntos)**Elija al menos 1 modelo grande del lenguaje, y usando los textos del dataset sin preprocesar, empleelo para clasificar los mensajes. Realice un muestreo del dataset con un tamaño del 30 %, 30 veces y reporte el F1-score y la tasa de aciertos. Reporte los resultados de forma clara y comentelos, con respecto a los resultados anteriores

2. (**10 puntos extra**) Escoja al menos 2 modelos más para agregar en la comparación.

3. (**10 puntos extra**) Entrene al menos uno de los dos modelos usando alguna tecnica eficiente de entrenamiento como DORA o LORA, reporte los resultados y analicelos.