# Trabajo práctico 2: revisión del proyecto

Lógica, pasos, resultados y decisiones

Alejandro Quesada Jose Herrera Manfred Azofeifa

24 de octubre de 2026

**Resumen**

Revisión interna del detector de spam: recoge la implementación en un único cuaderno, la auditoría del dataset, el modelo con sesgo y la evaluación de regresión logística con y sin PCA. Los resultados anteriores de MiniLM con 384 características no describen el nuevo codificador MPNet con 768 ni el protocolo de validación corregido. Se completaron 30 corridas por cada una de las cuatro variantes de regresión con MPNet. Este documento se mantiene junto con `TODO.md`, `AGENTS.md` y su PDF compilado.

## Índice

**1. Alcance y organización** **2**

**2. Auditoría del dataset y sus dimensiones** **2**

**3. Puntos 1.1 y 1.2: modelo básico con sesgo** **3**

**4. Punto 1.3: demostración aislada** **3**

**5. Punto 1.4: extracción y evaluación corregidas** **3**
5.1. Validación dentro de cada corrida . . . . . 3
5.2. Resultados de la nueva ejecución . . . . . 4

**6. Punto 1.5: reducción y comparación con PCA** **5**
6.1. Resultados y dimensión óptima . . . . . 5

**7. Puntos pendientes** **6**

**8. Registro de decisiones** **7**

**9. Verificación y reproducción** **7**

# 1. Alcance y organización

El enunciado pide detectar spam de SMSSpamCollection (UCI) mediante regresión logística propia, detección de anomalías por histogramas y modelos grandes de lenguaje. La entrega indicada en el enunciado es el 20 de octubre de 2026.

Desde el 24 de octubre se concentra toda la implementación en `notebooks/tp2_detector_spam.ipynb`: utilidades, funciones de los tres puntos, experimentos y análisis. Se retira la regla de un archivo por punto y el paquete `src/tp2/`. Se conserva la organización por apartados dentro del cuaderno, sin copias de las funciones en archivos Python.

| **Ubicación** | **Responsabilidad** |
|---|---|
| Cuaderno principal | Definiciones, configuración, ejecución y análisis en celdas diferenciadas. |
| `tests/` | Pruebas externas que ejecutan las definiciones del cuaderno. |
| `docs/report/sections/` | Informe LaTeX, organizado por punto. |
| `results/` | Figuras y tablas producidas por el cuaderno. |
| `data/raw/` | Dataset original versionado, sin modificaciones. |
| `data/processed/` | Cachés regenerables, excluidas de Git. |

Las celdas reutilizables comienzan por `# Definiciones:`. `tests/notebook_loader.py` las ejecuta en orden en un espacio de nombres común, sin ejecutar descargas, configuración de exportación ni experimentos. Así las pruebas comprueban la implementación que se entrega. Las dependencias opcionales se importan dentro de las funciones que las usan.

Se mantienen los contratos: características `float32` de forma $(n, D)$; etiquetas y predicciones `int64` de forma $(n,)$; ham $= 0$, spam $= 1$ y spam como clase positiva del F1. Las funciones reciben datos y parámetros explícitamente y llevan documentación Doxygen en español.

# 2. Auditoría del dataset y sus dimensiones

El archivo local `data/raw/SMSSpamCollection` coincide byte por byte con el del ZIP oficial de UCI. Su SHA256 es `7d039a24a6083ed9ef0f806ebad56bbb976e3aeb8de05669173bfdc4996c239d`. Tiene 5574 filas: 4827 ham y 747 spam. Cada fila contiene etiqueta y texto; no contiene 768 columnas de características. No hay mensajes vacíos ni errores de UTF-8. Hay 5171 textos únicos y 403 repeticiones adicionales, sin etiquetas contradictorias para un mismo texto.

**De dónde sale $D$.** El codificador anterior, `sentence-transformers/all-MiniLM-L6-v2`, produce 384 características. El equipo confirmó cambiar a `sentence-transformers/all-mpnet-base-v2`, que produce 768. Las fichas oficiales describen ambas dimensiones: MiniLM y MPNet. La dimensión depende del codificador; cambiarla exige recalcular características, calibración, métricas, tablas y figuras.

**Limitación de duplicados.** Se conserva el archivo original y el protocolo estratificado por filas. Por ello un texto idéntico puede aparecer en entrenamiento y prueba, lo que limita la interpretación como generalización a mensajes nuevos. Una evaluación agrupada por texto sería otro protocolo y requiere acordarla con el equipo; no se deduplicó silenciosamente.

# 3. Puntos 1.1 y 1.2: modelo básico con sesgo

El enunciado pide regresión logística. La confirmación del equipo mantiene una parte lineal básica con sesgo y una sigmoide:

$$z = Xw + b, \qquad p(y = 1 \mid x) = \sigma(z).$$

`forward` calcula probabilidades; el sesgo es un escalar entrenable. La sigmoide se evalúa con $e^{-|z|}$ para evitar desbordamientos con logits extremos. El entrenamiento propio minimiza la entropía cruzada binaria media con descenso del gradiente por lotes completos:

$$\nabla_w L = X^\top (p - y)/n, \qquad \partial L/\partial b = \overline{p - y}.$$

Se actualizan tanto $w$ como $b$. No se utilizan `torch.nn`, optimizadores de `torch.optim` ni clasificadores ya implementados. La pérdida se calcula a partir de logits de forma estable. El historial conserva la pérdida inicial y una por época.

Las cuatro pruebas obligatorias verifican probabilidades con pesos nulos, sigmoide y estabilidad extrema, primer paso de gradiente (incluido el sesgo) y clasificación reproducible de datos separables. En pruebas se permite Autograd como referencia independiente.

# 4. Punto 1.3: demostración aislada

El conjunto sintético bidimensional verifica el entrenamiento y la evolución de su frontera frente a una recta conocida con sesgo. Se conservan sus propias semillas, tasa y épocas. Sus datos, modelo e hiperparámetros no se usan en 1.4, 1.5 ni 2: esos apartados trabajan exclusivamente con los mensajes UCI y sus características. Las funciones genéricas `forward` y de entrenamiento son compartidas; los resultados experimentales no lo son.

# 5. Punto 1.4: extracción y evaluación corregidas

Se codifica cada mensaje original con MPNet y se verifica forma $(5574, 768)$, tipo `float32`, orden de las filas y valores finitos. La caché identifica el dataset y el codificador para impedir reutilizar características de otro modelo o archivo. El codificador preentrenado no se ajusta sobre UCI, así que la extracción puede realizarse una vez antes de las particiones.

## 5.1. Validación dentro de cada corrida

Se mantienen 30 particiones estratificadas 70 %/30 %, con semillas $2026, \ldots, 2055$. En cada una:

1. Se reserva el 30 % para prueba y no se usa al seleccionar parámetros.
2. Se divide el entrenamiento en 80 % de ajuste y 20 % de validación.
3. Se prueban tasas $\{0.1, 0.5, 1, 2, 5, 10, 20, 50\}$ y épocas $\{250, 500, 1000, 2000, 4000\}$. Se elige mayor F1 de validación y, en caso de empate, menor pérdida de validación.
4. Se aplica automáticamente la combinación ganadora al entrenar un modelo nuevo sobre todo el 70 % de entrenamiento; se evalúa una vez en su prueba.

Antes se calibraba una sola vez con la primera partición y se reutilizaba la elección en las otras 29. Esa validación incluía 244 mensajes que luego estaban en la prueba de la semilla 2027 y 226 de la semilla 2028. Por tanto esas pruebas no estaban aisladas de la selección global. No se puede afirmar que el sesgo fuera pequeño sin medirlo. Además, la calibración solo imprimía una advertencia si su ganador no coincidía con las constantes manuales; ahora se consume el ganador directamente.

### 5.2. Resultados de la nueva ejecución

Se ejecutaron las 30 corridas completas con MPNet/768, antes de ejecutar la demostración 1.3: la evaluación no necesita sus datos ni su entrenamiento. Las cifras son medias y desviaciones muestrales entre corridas.

| Métrica | Media | Desviación | Mínimo | Máximo |
|---|---|---|---|---|
| Tasa de aciertos | 0.9906 | 0.0016 | 0.9874 | 0.9940 |
| F1 | 0.9641 | 0.0063 | 0.9519 | 0.9776 |

En la primera corrida la validación eligió tasa 20 y 4000 épocas, con F1 0.9714. Es un ejemplo de selección interna, no una constante para las demás corridas: sus elecciones se registran en la tabla exportada de hiperparámetros. La mejora frente a cifras históricas no permite atribuir el cambio solo al codificador, porque también se corrigió el protocolo de selección.

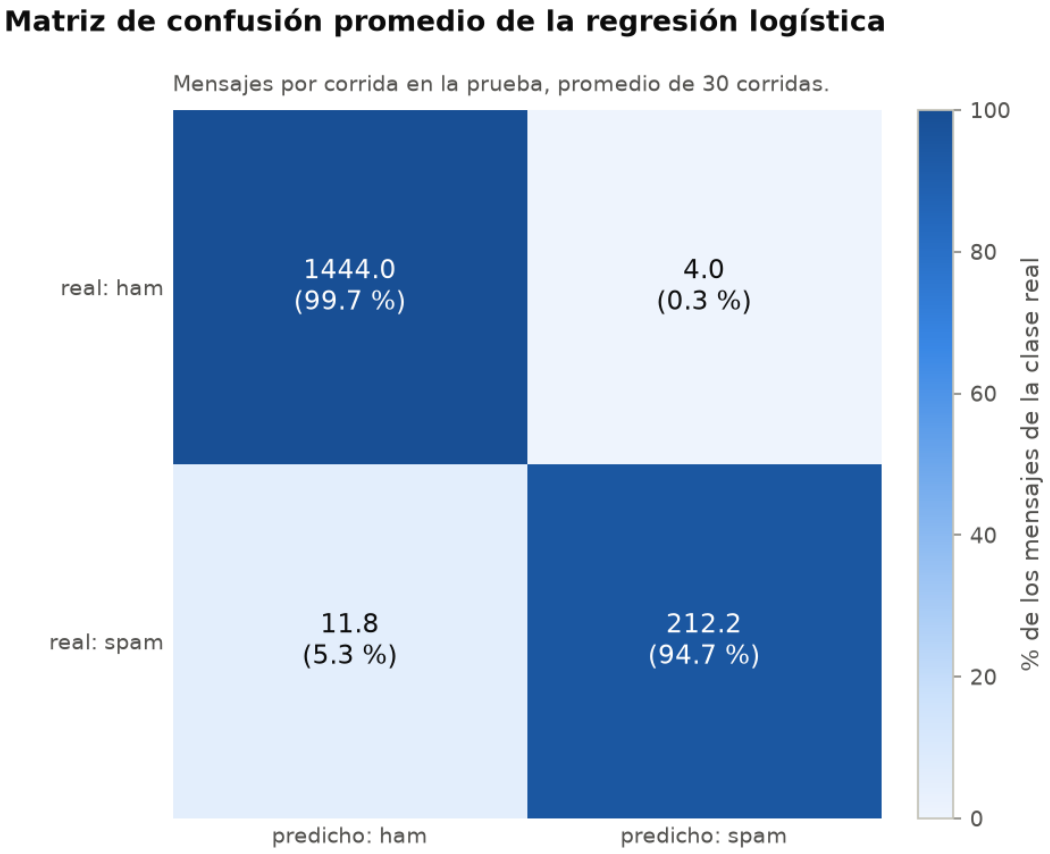



Figura 1: Errores medios de las 30 pruebas con MPNet/768, después de la calibración interna de cada corrida.

# 6. Punto 1.5: reducción y comparación con PCA

Con $D = 768$ se comparan $k = 384$ (50 %), $k = 192$ (25 %) y $k = 2$ con el caso sin PCA. Se conserva PCA propio por SVD de datos centrados, cálculo en doble precisión y signo fijo de cada componente. La proyección recibe la media y componentes obtenidas del conjunto de ajuste correspondiente.

La calibración se repite para cada corrida y cada $k$. Durante la selección, el PCA se ajusta solo con el ajuste interno y transforma la validación. Tras elegir tasa y épocas se reajusta PCA sobre todo el entrenamiento externo; se entrena allí y se transforma la prueba sin reajustarlo. Comparar las mismas semillas permite calcular diferencias pareadas de F1. Las proyecciones y la varianza de todo el dataset son diagnósticos descriptivos, no criterios para consultar la prueba al elegir hiperparámetros.

## 6.1. Resultados y dimensión óptima

Se completaron las 90 corridas con PCA y las 30 sin PCA, con las mismas semillas. La varianza corresponde al PCA descriptivo sobre todo el dataset; las métricas usan únicamente PCA ajustados con el entrenamiento correspondiente.

| $k$ | Varianza | Tasa de aciertos | F1 | $\Delta$ F1 pareado |
|---|---|---|---|---|
| 768 | 100 % | $0.9906 \pm 0.0016$ | $0.9641 \pm 0.0063$ | — |
| 384 | 96.16 % | $0.9905 \pm 0.0019$ | $0.9637 \pm 0.0075$ | $-0.0004$ |
| 192 | 84.13 % | $0.9894 \pm 0.0021$ | $0.9596 \pm 0.0082$ | $-0.0045$ |
| 2 | 8.08 % | $0.9466 \pm 0.0054$ | $0.7845 \pm 0.0189$ | $-0.1796$ |

Con 384 componentes el F1 es menor que sin PCA en 14 de las 30 particiones; la diferencia pareada es $-0.0004 \pm 0.0030$. Con 192, baja en 24 de las 30, con diferencia $-0.0045 \pm 0.0054$. Con 2 baja en todas, con diferencia $-0.1796 \pm 0.0198$: se escapan 61.4 spam por prueba frente a 11.8 sin PCA, y los ham marcados como spam suben de 4.0 a 27.9.

Las 384 componentes conservan casi toda la varianza y un F1 medio próximo al del caso completo. Las 192 vuelven a reducir a la mitad el número de características con mayor pérdida media. Dos dimensiones sirven para visualizar, pero pierden información relevante para clasificar. La desviación entre particiones solapadas no es un intervalo de confianza de muestras independientes. No se atribuye significación estadística a la diferencia pequeña con 384 componentes.

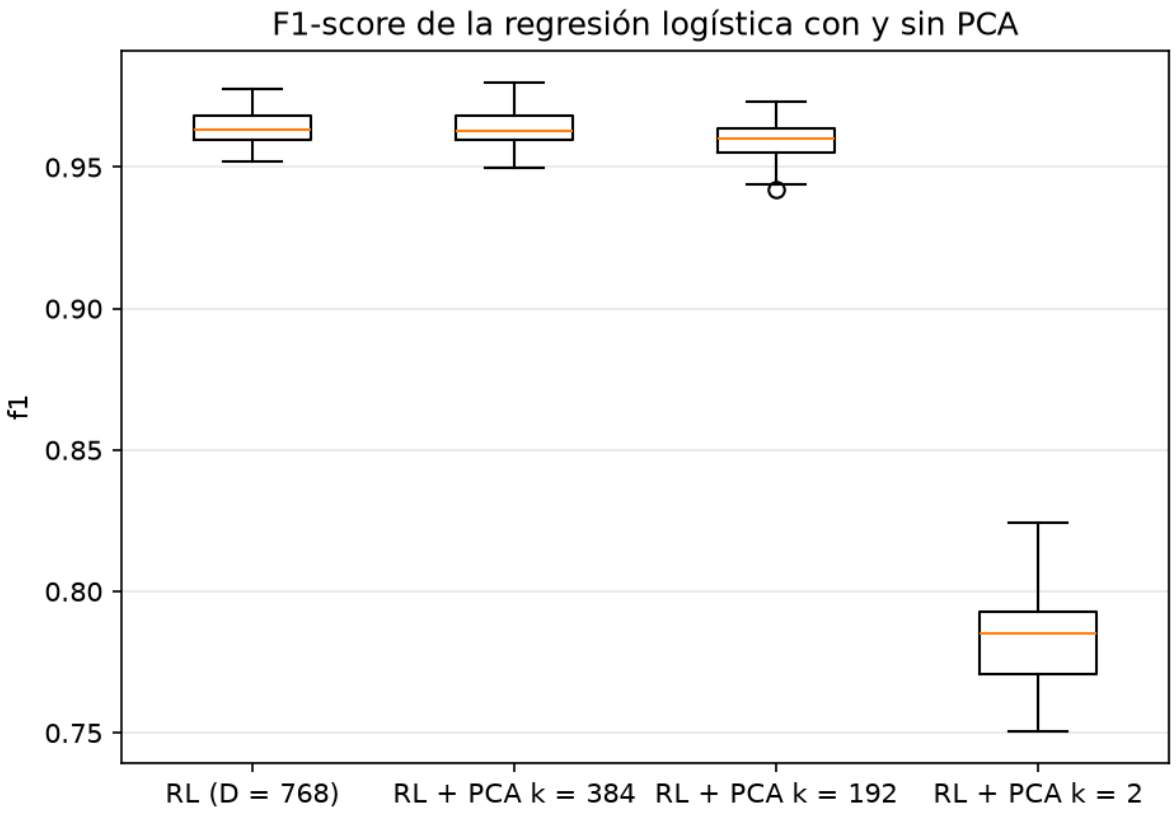



Figura 2: F1 en las mismas 30 particiones, con validación interna por método y corrida.

El equipo confirmó `OPTIMAL_PCA_DIMENSIONS = 384` el 24 de octubre de 2026. Se reduce a la mitad la dimensión inicial de MPNet y se conserva el 96.16 % de la varianza descriptiva. El F1 medio es 0.9637 frente a 0.9641 sin PCA, con diferencia media pareada de $-0.0004$. Esta cercanía no demuestra equivalencia estadística; se adopta como compromiso entre reducción y clasificación observada. El punto 2 usará 384 histogramas, uno por componente. La decisión se basa en MPNet/768 y no en las recomendaciones anteriores de MiniLM/384.

## 7. Puntos pendientes

El punto 2 mantiene sus funciones pendientes de densidad por histogramas, verosimilitud, umbral y gráficas; su dimensión ya está fijada en 384 a partir de 1.5, con un histograma por componente. El equipo debe confirmar qué datos construyen las densidades, el criterio del umbral y la cantidad de intervalos. El punto 3 conserva los textos originales y requiere elegir modelos, prompt y tratamiento de respuestas ambiguas. LoRA o DoRA siguen pendientes. Estas tareas y sus pruebas no se eliminan; la ejecución final de todo el cuaderno espera a que estén implementadas.

## 8. Registro de decisiones

| Fecha | Decisión | Motivo |
|---|---|---|
| 17/10/2026 | Sigmoide estable y gradiente exacto propio. | Implementación transparente sin desbordamientos ni optimizadores externos. |
| 19/10/2026 | Frontera verdadera fija en 1.3. | Comparar la recta aprendida con una referencia con sesgo. |
| 23/10/2026 | 1.3 independiente de UCI; dataset original versionado. | Evitar mezclar demostración sintética y evaluación real; compartir los mismos datos. |
| 23/10/2026 | PCA por SVD centrada y comparación pareada. | Ajuste propio y comparación sobre las mismas particiones. |
| 24/10/2026 | Único notebook con toda la implementación. | Sustituye archivos por punto y utilidades separadas; pruebas consumen las mismas definiciones. |
| 24/10/2026 | Mantener logística $Xw + b$ seguida de sigmoide. | Confirmación del equipo; coincide con 1.1 y 1.2 del enunciado. |
| 24/10/2026 | MPNet con 768 características; descargar y ejecutar 1.4–1.5. | Confirmación del equipo; reemplaza MiniLM/384 y sus resultados. |
| 24/10/2026 | Calibración interna por corrida y cantidad de componentes. | Aislar cada prueba y usar el ganador automáticamente. |
| 24/10/2026 | Conservar duplicados y documentar su limitación. | Mantener el dataset original y el protocolo por filas sin introducir otra evaluación. |
| 24/10/2026 | Fijar $D = 384$ para el punto 2. | Decisión del equipo: mitad de las características, 96.16 % de varianza descriptiva y F1 medio 0.9637 frente a 0.9641 sin PCA; no implica equivalencia estadística. |

## 9. Verificación y reproducción

- `pytest`: 30 pruebas superadas, 2 pendientes (2.1 y 3.1), 0 fallidas, en terminal y cuaderno. Incluye búsqueda vectorizada equivalente al entrenamiento individual, aislamiento de prueba, PCA interno y rechazo de cachés incompatibles.
- Cuaderno guardado validado con `nbformat`, IDs únicos y análisis sintáctico. Se conservan documentación Doxygen, sesgo y gradiente.
- Dataset contrastado con el original UCI. Características MPNet $(5574, 768)$, finitas, `float32` y de norma 1. Las cuatro variantes completaron 30 corridas con semillas 2026–2055. Toda la evaluación UCI se completó antes de crear los datos sintéticos de 1.3.
- La inspección estática del IDE no resuelve algunos imports de pruebas y atributos del módulo cargado dinámicamente; su ejecución real y las pruebas los verifican. El informe preliminar también compila (17 páginas), con los puntos 2 y 3 todavía pendientes.
- Figuras inspeccionadas visualmente y PDF compilado con `./build_pdf.sh review`. La ejecución final y Doxygen siguen pendientes, al igual que los puntos 2 y 3.

Para reproducir, instalar `requirements.txt` y ejecutar las definiciones, configuración, datos y punto 1 completos del cuaderno. La configuración limpia las exportaciones: regenerar las figuras antes de compilar documentos que las usen.