Trabajo práctico 2: revisión del proyecto

Lógica, pasos, resultados y decisiones

Alejandro Quesada Jose Herrera Manfred Azofeifa

24 de octubre de 2026

Resumen

Revisión interna de los puntos 1 y 2: regresión logística propia, PCA y detección por histogramas con MPNet de 768 características. Se verificaron 30 corridas por método, 48 pruebas superadas y una pendiente del punto 3. La auditoría corrigió la derivada de la sigmoide en cero y comparó alternativas de calibración. Ampliar la regresión no mejoró F1; calibrar el detector redujo falsas alarmas, pero dejó escapar más spam. La variante $D = 2$ del equipo difiere de reutilizar $D = 384$, como pide la lectura literal del enunciado: su aceptación sigue pendiente. Se mantienen las configuraciones vigentes y el punto 3 queda fuera del alcance.

Índice

1. Alcance y organización **2**

2. Auditoría del dataset y sus dimensiones **2**

3. Puntos 1.1 y 1.2: modelo básico con sesgo **3**

4. Punto 1.3: demostración aislada **3**

5. Punto 1.4: extracción y evaluación corregidas **3**
5.1. Validación dentro de cada corrida . . . 3
5.2. Resultados de la nueva ejecución . . . 4

6. Punto 1.5: reducción y comparación con PCA **5**
6.1. Resultados y dimensión óptima . . . 5

7. Punto 2.1: densidades por histograma y umbral **6**

8. Punto 2.2: evaluación en 30 corridas **8**

9. Auditoría de los puntos 1 y 2 (24/10/2026) **9**
9.1. Cobertura del enunciado . . . 9
9.2. Límites de las conclusiones anteriores . . . 10
9.3. Experimento adicional reproducible . . . 10

10. Puntos pendientes **11**

11. Registro de decisiones **12**

12. Verificación y reproducción **13**

1. Alcance y organización

El enunciado pide detectar spam de SMSSpamCollection (UCI) mediante regresión logística propia, detección de anomalías por histogramas y modelos grandes de lenguaje. La entrega indicada en el enunciado es el 20 de octubre de 2026.

Desde el 24 de octubre se concentra toda la implementación en `notebooks/tp2_detector_spam.ipynb`: utilidades, funciones de los tres puntos, experimentos y análisis. Se retira la regla de un archivo por punto y el paquete `src/tp2/`. Se conserva la organización por apartados dentro del cuaderno, sin copias de las funciones en archivos Python.

Ubicación	**Responsabilidad**
Cuaderno principal	Definiciones, configuración, ejecución y análisis en celdas diferenciadas.
`tests/`	Pruebas externas que ejecutan las definiciones del cuaderno.
`docs/report/sections/`	Informe LaTeX, organizado por punto.
`results/`	Figuras y tablas producidas por el cuaderno.
`data/raw/`	Dataset original versionado, sin modificaciones.
`data/processed/`	Cachés regenerables, excluidas de Git.

Las celdas reutilizables comienzan por `# Definiciones:`. `tests/notebook_loader.py` las ejecuta en orden en un espacio de nombres común, sin ejecutar descargas, configuración de exportación ni experimentos. Así las pruebas comprueban la implementación que se entrega. Las dependencias opcionales se importan dentro de las funciones que las usan.

Se mantienen los contratos: características `float32` de forma (n, D); etiquetas y predicciones `int64` de forma $(n,)$; ham $= 0$, spam $= 1$ y spam como clase positiva del F1. Las funciones reciben datos y parámetros explícitamente y llevan documentación Doxygen en español.

2. Auditoría del dataset y sus dimensiones

El archivo local `data/raw/SMSSpamCollection` coincide byte por byte con el del ZIP oficial de UCI. Su SHA256 es `7d039a24a6083ed9ef0f806ebad56bbb976e3aeb8de05669173bfdc4996c239d`. Tiene 5574 filas: 4827 ham y 747 spam. Cada fila contiene etiqueta y texto; no contiene 768 columnas de características. No hay mensajes vacíos ni errores de UTF-8. Hay 5171 textos únicos y 403 repeticiones adicionales, sin etiquetas contradictorias para un mismo texto.

De dónde sale D. El codificador anterior, `sentence-transformers/all-MiniLM-L6-v2`, produce 384 características. El equipo confirmó cambiar a `sentence-transformers/all-mpnet-base-v2`, que produce 768. Las fichas oficiales describen ambas dimensiones: MiniLM y MPNet. La dimensión depende del codificador; cambiarla exige recalcular características, calibración, métricas, tablas y figuras.

Limitación de duplicados. Se conserva el archivo original y el protocolo estratificado por filas. Por ello un texto idéntico puede aparecer en entrenamiento y prueba, lo que limita la interpretación como generalización a mensajes nuevos. Una evaluación agrupada por texto sería otro protocolo y requiere acordarla con el equipo; no se deduplicó silenciosamente.

3. Puntos 1.1 y 1.2: modelo básico con sesgo

El enunciado pide regresión logística. La confirmación del equipo mantiene una parte lineal básica con sesgo y una sigmoide:

$$z = Xw + b, \qquad p(y = 1 \mid x) = \sigma(z).$$

`forward` calcula probabilidades; el sesgo es un escalar entrenable. La sigmoide se evalúa con $e^{-|z|}$ para evitar desbordamientos con logits extremos. El entrenamiento propio minimiza la entropía cruzada binaria media con descenso del gradiente por lotes completos:

$$\nabla_w L = X^\top (p - y)/n, \qquad \partial L/\partial b = \overline{p - y}.$$

Se actualizan tanto w como b. No se utilizan `torch.nn`, optimizadores de `torch.optim` ni clasificadores ya implementados. La pérdida se calcula a partir de logits de forma estable. El historial conserva la pérdida inicial y una por época.

Las cuatro pruebas obligatorias verifican probabilidades con pesos nulos, sigmoide y estabilidad extrema, primer paso de gradiente (incluido el sesgo) y clasificación reproducible de datos separables. En pruebas se permite Autograd como referencia independiente.

4. Punto 1.3: demostración aislada

El conjunto sintético bidimensional verifica el entrenamiento y la evolución de su frontera frente a una recta conocida con sesgo. Se conservan sus propias semillas, tasa y épocas. Sus datos, modelo e hiperparámetros no se usan en 1.4, 1.5 ni 2: esos apartados trabajan exclusivamente con los mensajes UCI y sus características. Las funciones genéricas `forward` y de entrenamiento son compartidas; los resultados experimentales no lo son.

5. Punto 1.4: extracción y evaluación corregidas

Se codifica cada mensaje original con MPNet y se verifica forma $(5574, 768)$, tipo `float32`, orden de las filas y valores finitos. La caché identifica el dataset y el codificador para impedir reutilizar características de otro modelo o archivo. El codificador preentrenado no se ajusta sobre UCI, así que la extracción puede realizarse una vez antes de las particiones.

5.1. Validación dentro de cada corrida

Se mantienen 30 particiones estratificadas 70 %/30 %, con semillas $2026, \ldots, 2055$. En cada una:

1. Se reserva el 30 % para prueba y no se usa al seleccionar parámetros.
2. Se divide el entrenamiento en 80 % de ajuste y 20 % de validación.
3. Se prueban tasas $\{0.1, 0.5, 1, 2, 5, 10, 20, 50\}$ y épocas $\{250, 500, 1000, 2000, 4000\}$. Se elige mayor F1 de validación y, en caso de empate, menor pérdida de validación.
4. Se aplica automáticamente la combinación ganadora al entrenar un modelo nuevo sobre todo el 70 % de entrenamiento; se evalúa una vez en su prueba.

Antes se calibraba una sola vez con la primera partición y se reutilizaba la elección en las otras 29. Esa validación incluía 244 mensajes que luego estaban en la prueba de la semilla 2027 y 226 de la semilla 2028. Por tanto esas pruebas no estaban aisladas de la selección global. No se puede afirmar que el sesgo fuera pequeño sin medirlo. Además, la calibración solo imprimía una advertencia si su ganador no coincidía con las constantes manuales; ahora se consume el ganador directamente.

5.2. Resultados de la nueva ejecución

Se ejecutaron las 30 corridas completas con MPNet/768, antes de ejecutar la demostración 1.3: la evaluación no necesita sus datos ni su entrenamiento. Las cifras son medias y desviaciones muestrales entre corridas.

Métrica	Media	Desviación	Mínimo	Máximo
Tasa de aciertos	0.9906	0.0016	0.9874	0.9940
F1	0.9641	0.0063	0.9519	0.9776

En la primera corrida la validación eligió tasa 20 y 4000 épocas, con F1 0.9714. Es un ejemplo de selección interna, no una constante para las demás corridas: sus elecciones se registran en la tabla exportada de hiperparámetros. La mejora frente a cifras históricas no permite atribuir el cambio solo al codificador, porque también se corrigió el protocolo de selección.

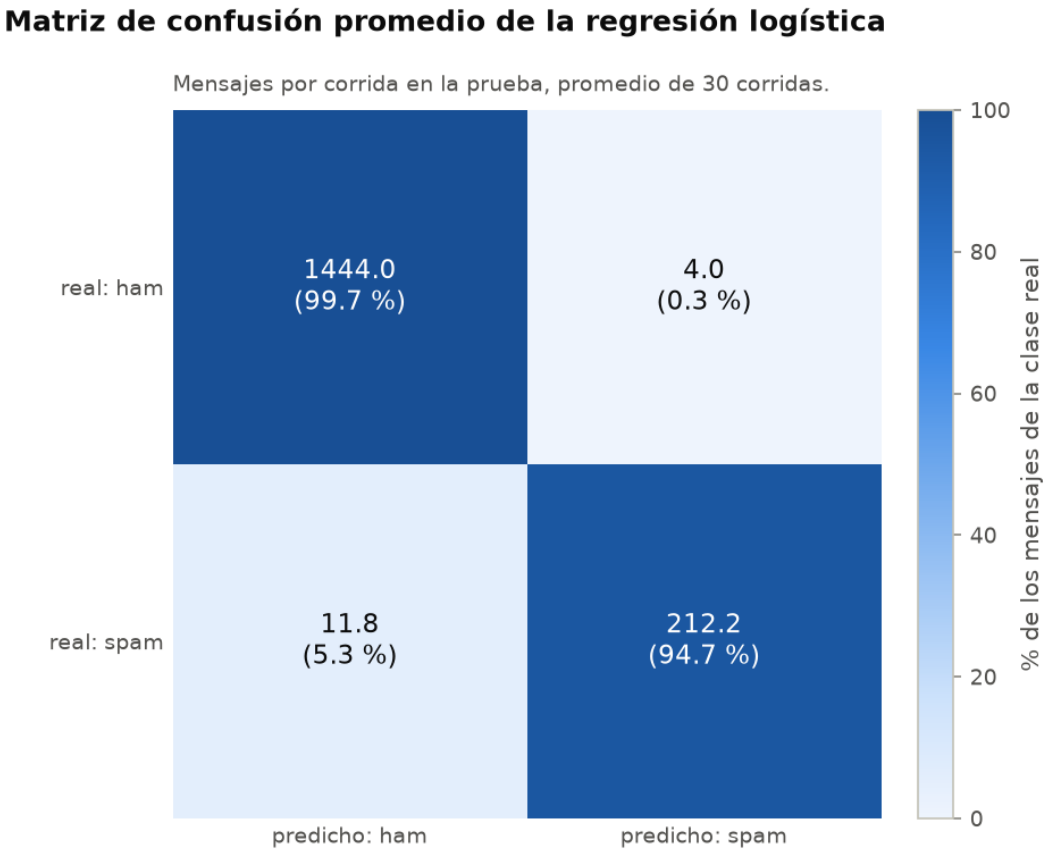


Figura 1: Errores medios de las 30 pruebas con MPNet/768, después de la calibración interna de cada corrida.

6. Punto 1.5: reducción y comparación con PCA

Con $D = 768$ se comparan $k = 384$ (50 %), $k = 192$ (25 %) y $k = 2$ con el caso sin PCA. Se conserva PCA propio por SVD de datos centrados, cálculo en doble precisión y signo fijo de cada componente. La proyección recibe la media y componentes obtenidas del conjunto de ajuste correspondiente.

La calibración se repite para cada corrida y cada k. Durante la selección, el PCA se ajusta solo con el ajuste interno y transforma la validación. Tras elegir tasa y épocas se reajusta PCA sobre todo el entrenamiento externo; se entrena allí y se transforma la prueba sin reajustarlo. Comparar las mismas semillas permite calcular diferencias pareadas de F1. Las proyecciones y la varianza de todo el dataset son diagnósticos descriptivos, no criterios para consultar la prueba al elegir hiperparámetros.

6.1. Resultados y dimensión óptima

Se completaron las 90 corridas con PCA y las 30 sin PCA, con las mismas semillas. La varianza corresponde al PCA descriptivo sobre todo el dataset; las métricas usan únicamente PCA ajustados con el entrenamiento correspondiente.

k	Varianza	Tasa de aciertos	F1	Δ F1 pareado
768	100 %	0.9906 ± 0.0016	0.9641 ± 0.0063	—
384	96.16 %	0.9905 ± 0.0019	0.9637 ± 0.0075	-0.0004
192	84.13 %	0.9894 ± 0.0021	0.9596 ± 0.0082	-0.0045
2	8.08 %	0.9466 ± 0.0054	0.7845 ± 0.0189	-0.1796

Con 384 componentes el F1 es menor que sin PCA en 14 de las 30 particiones; la diferencia pareada es -0.0004 ± 0.0030. Con 192, baja en 24 de las 30, con diferencia -0.0045 ± 0.0054. Con 2 baja en todas, con diferencia -0.1796 ± 0.0198: se escapan 61.4 spam por prueba frente a 11.8 sin PCA, y los ham marcados como spam suben de 4.0 a 27.9.

Las 384 componentes conservan casi toda la varianza y un F1 medio próximo al del caso completo. Las 192 vuelven a reducir a la mitad el número de características con mayor pérdida media. Dos dimensiones sirven para visualizar, pero pierden información relevante para clasificar. La desviación entre particiones solapadas no es un intervalo de confianza de muestras independientes. No se atribuye significación estadística a la diferencia pequeña con 384 componentes.

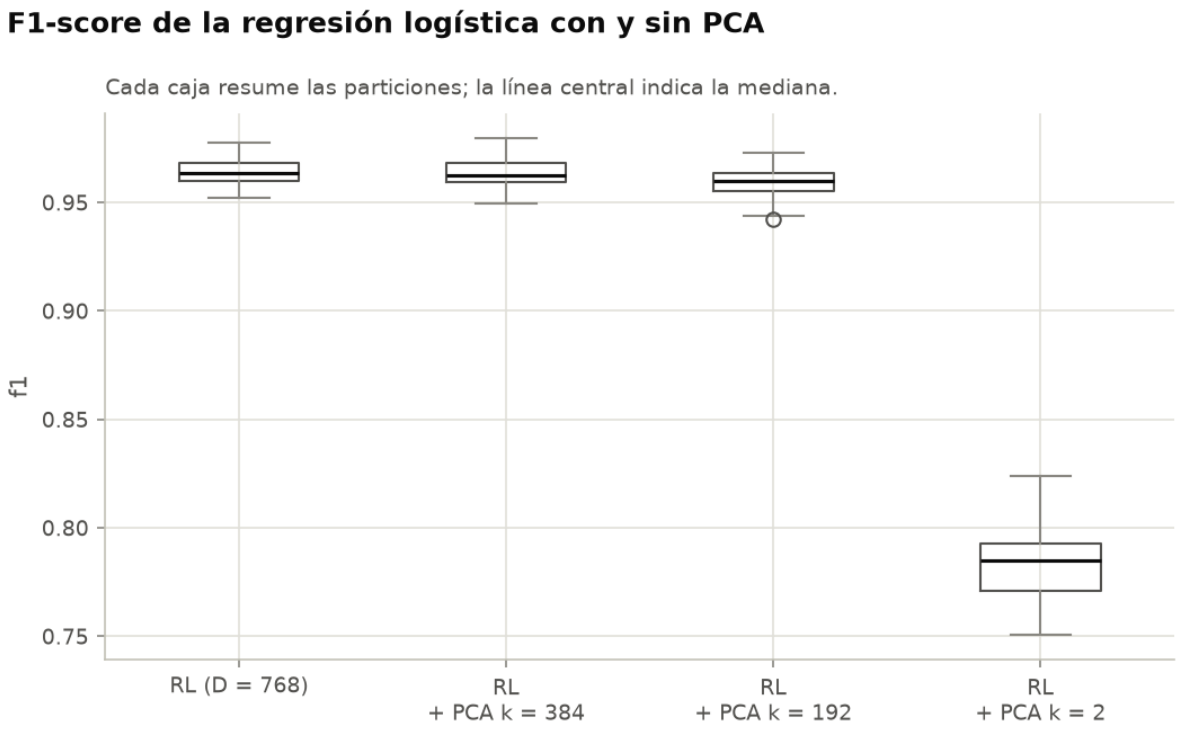


Figura 2: F1 en las mismas 30 particiones, con validación interna por método y corrida.

El equipo confirmó `OPTIMAL_PCA_DIMENSIONS = 384` el 24 de octubre de 2026. Se reduce a la mitad la dimensión inicial de MPNet y se conserva el 96.16 % de la varianza descriptiva. El F1 medio es 0.9637 frente a 0.9641 sin PCA, con diferencia media pareada de -0.0004. Esta cercanía no demuestra equivalencia estadística; se adopta como compromiso entre reducción y clasificación observada para la regresión logística. La decisión se basa en MPNet/768 y no en las recomendaciones anteriores de MiniLM/384. El detector del punto 2 compara estos mismos casos con su propia validación (Sección 7).

7. Punto 2.1: densidades por histograma y umbral

Lógica. En cada partición se ajusta un PCA solo con el entrenamiento. Por componente se estima un histograma de 30 intervalos de igual ancho entre el mínimo y el máximo de los datos, normalizado para que integre 1. El puntaje es $\sum_d \log p_d(x_d)$; un valor en un intervalo vacío o fuera del soporte recibe $\varepsilon = 10^{-12}$ ($\log \varepsilon \approx -27.6$) sin recortar el dato. Un puntaje menor que el umbral marca spam.

Pasos.

1. Se implementaron `fit_histogram_densities`, `per_dimension_log_likelihood`, `log_likelihood`, `select_threshold` (cuantil con interpolación lineal) y las gráficas, hasta superar las nueve pruebas ya escritas para el 2.1.

2. `fit_anomaly_detector` reparte los ham del entrenamiento: el 80 % construye los histogramas y el 20 % reservado da los puntajes del cuantil 5 %. Si el umbral sale de los mismos ham de los histogramas, ninguno cae fuera del soporte y el umbral queda sesgado. En la primera

partición, con 384 componentes, quedaba marcado el 17.3 % de los ham de prueba en lugar del 5 % (7.9 % con ham reservado); con 2 componentes el efecto es menor: 5.9 % frente a 4.4 %.

3. Con 384 componentes el detector casi no encuentra spam. Se diagnosticó con la brecha por componente (media de $\log p_d$ de ham menos la de spam) y se compararon los casos de 1.5 en la validación interna de los 30 entrenamientos, sin usar la prueba de esa misma corrida.

4. Se agregaron cinco pruebas: suma por dimensión, umbral con filas reservadas, candidatos con columnas iniciales y solo ham, signo de la brecha y títulos de las figuras nuevas.

Resultados de la selección. Validación interna (20 % estratificado del entrenamiento, como en 1.4) de las 30 particiones; media ± desviación:

D	Tasa de aciertos	F1	Spam detectado	Ham marcado	Gana
384	0.7812 ± 0.0141	0.0401 ± 0.0193	3.4 %	10.3 %	0
192	0.8425 ± 0.0072	0.0237 ± 0.0191	1.4 %	2.9 %	0
2	0.9201 ± 0.0106	0.7085 ± 0.0318	72.1 %	4.9 %	30

En la primera partición, la brecha de la componente 1 es 12.8 y es negativa en 330 de las 384 componentes: el spam está más concentrado que el ham y recibe más densidad. La brecha acumulada vale +12.6 con 2 componentes, cruza cero en 169, vale −2.8 con 192 y −41.1 con 384. Su máximo (14.2, con 11) no se evaluó porque el equipo restringió la búsqueda a los tres casos de 1.5. El enunciado pide reutilizar la D óptima anterior, sin prescribir esa búsqueda para el detector.

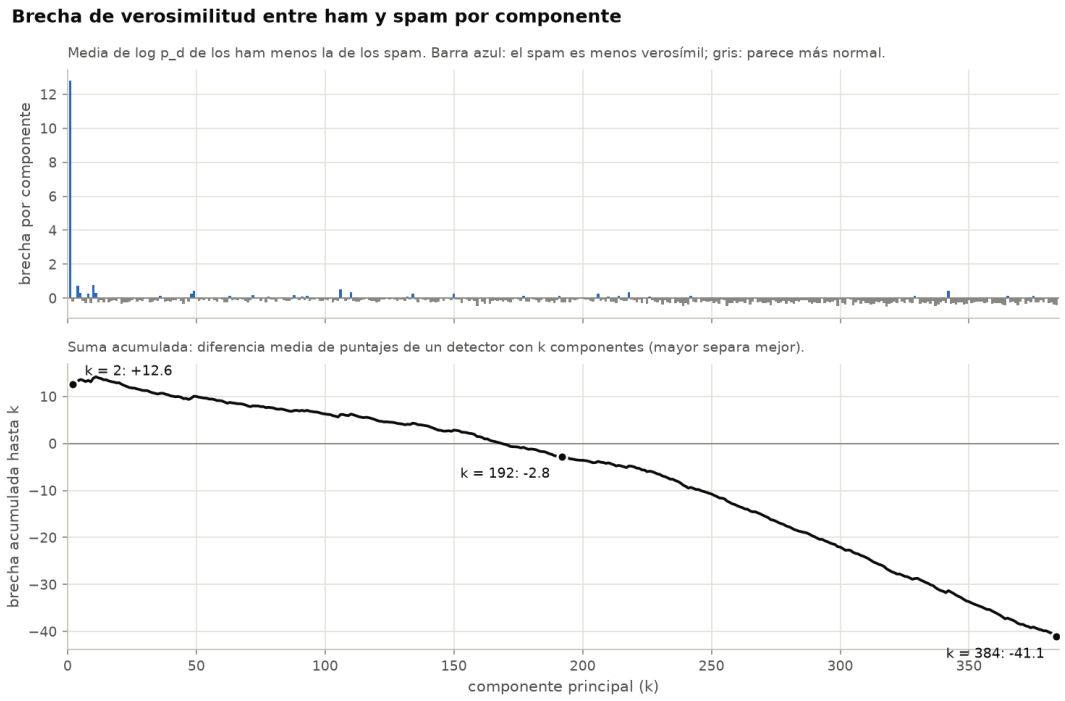


Figura 3: Brecha de verosimilitud por componente y acumulada (primera partición, validación).

Demostración con $D = 2$. Semilla 2026: 2703 ham construyen los histogramas, 676 fijan el umbral $\tau = -0.8334$. En su prueba queda bajo el umbral el 4.4 % de los ham y el 75.9 % del spam

(tasa de aciertos 0.9294, F1 0.7424). El 50 % del spam queda fuera del soporte de la componente 1 y el 25.9 % cae en zonas de baja densidad; el resto se mezcla con el ham.

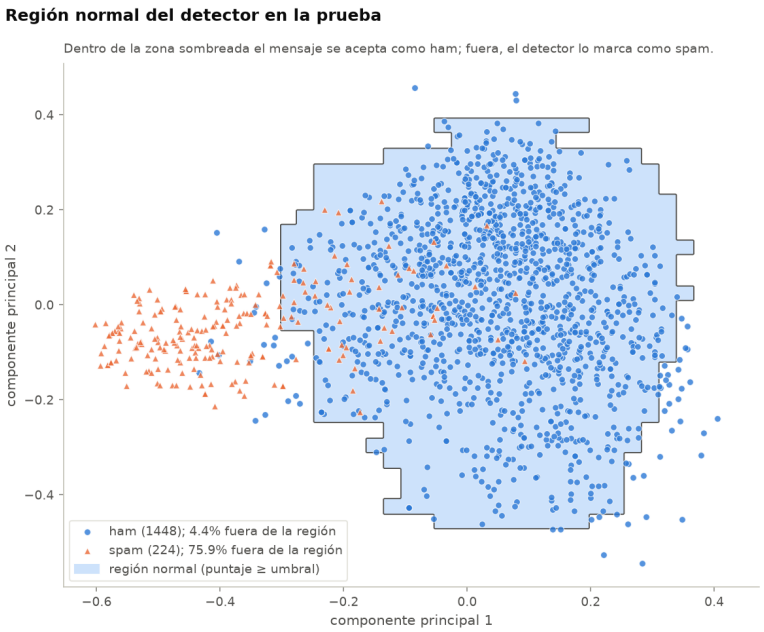


Figura 4: Región normal del detector con $D = 2$ y mensajes de prueba (semilla 2026).

8. Punto 2.2: evaluación en 30 corridas

Pasos. La celda del 2.2 repite el detector del 2.1 en las 30 particiones de la regresión (semillas 2026–2055), con PCA, histogramas y umbral ajustados solo con cada entrenamiento. Además de la tabla de medias, compara corrida a corrida con la regresión sin PCA y con la regresión de $k = 2$, y reporta los errores por clase. Para tener los resultados por partición del punto 1 se volvieron a ejecutar sus 120 corridas en esta máquina: las tablas de métricas coinciden exactamente con las versionadas.

Resultados. Media ± desviación; errores promedio por prueba (1448 ham y 224 spam):

Método	Tasa de aciertos	F1	Ham marcado	Spam detectado
Regresión, 768	0.9906 ± 0.0016	0.9641 ± 0.0063	4.0	94.7 %
Regresión, $k = 2$	0.9466 ± 0.0054	0.7845 ± 0.0189	27.9	72.6 %
Histogramas, $D = 2$	0.9195 ± 0.0084	0.7043 ± 0.0247	70.5	71.4 %

Diferencia pareada de F1 del detector: -0.2597 ± 0.0253 frente a la regresión sin PCA y -0.0802 ± 0.0212 frente a $k = 2$; menor en las 30 corridas en ambos casos. El F1 de validación del 2.1 (0.7085) anticipó el de prueba (0.7043). Con 2 componentes, ambos métodos detectan una fracción similar de spam; el detector marca más ham (4.9 % contra 1.9 %) porque su umbral acepta el 5 % de los ham y no sabe hacia dónde está el spam.

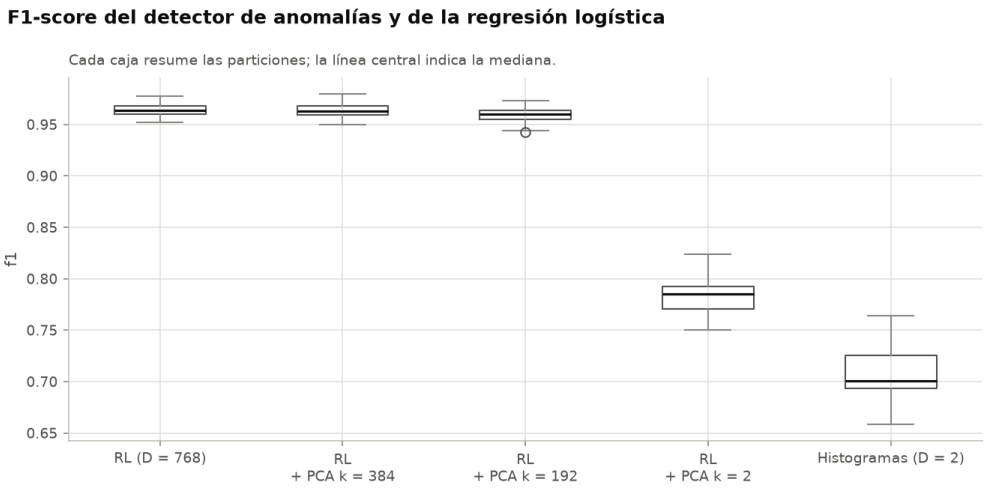


Figura 5: F1 del detector y de la regresión en las mismas 30 particiones.

9. Auditoría de los puntos 1 y 2 (24/10/2026)

9.1. Cobertura del enunciado

Se revisaron las definiciones y llamadas del cuaderno, las pruebas externas, las tablas exportadas y las secciones LaTeX contra las dos páginas del enunciado. El punto 3 queda fuera del alcance de esta auditoría.

1.1 y 1.2. Implementaciones propias de evaluación y descenso del gradiente en PyTorch, sin capas ni optimizadores prefabricados. Hay dos pruebas obligatorias por función. Una prueba adicional descubrió que `abs` anulaba la derivada de la sigmoide en logit cero; la selección explícita de la rama conserva $\sigma'(0) = 1/4$. Los valores del forward y el gradiente manual del entrenamiento se conservan.

1.3. Datos sintéticos separables, con prueba independiente, tablas, pérdida y fronteras. El ángulo casi coincide con el verdadero, pero el sesgo normalizado sigue desplazado: clasificar todo bien no identifica una única frontera verdadera.

1.4 y 1.5. Codificador MPNet, 30 particiones 70/30, tasa de aciertos, F1 de spam y PCA a 384, 192 y 2 componentes. La selección de tasa y épocas y el ajuste de PCA excluyen la prueba de cada corrida. El PCA sobre todos los datos se usa solo para figuras descriptivas. Las secciones del informe ya estaban redactadas; se corrigen sus afirmaciones y se amplía la evidencia.

2.1. Histogramas normalizados por dimensión, suma de logaritmos, umbral y figuras implementados y probados. La decisión del equipo de usar $D = 2$ difiere de reutilizar $D = 384$, como pide la lectura literal. Se conserva esa decisión y se añade una referencia con 384 componentes; queda pendiente validar con el docente si acepta la variante.

2.2. Se evalúan 30 particiones compartidas con el punto 1 y se comparan ambas métricas y los errores por clase. No debe darse por cerrado el cumplimiento de 2.1 únicamente por el mejor F1 de la variante.

9.2. Límites de las conclusiones anteriores

Las 30 particiones se solapan. Cada validación interna excluye su propia prueba, pero agregar todas para elegir una única dimensión permite que una fila de prueba de una corrida participe en la decisión a través de otra. Aquí $D = 2$ gana en las 30 validaciones: seleccionarla por corrida da la misma dimensión observada, sin demostrar ausencia de sesgo de desarrollo. La elección del compromiso $D = 384$ en 1.5 también se apoyó en la comparación de métricas de prueba; sus resultados se interpretan como comparación descriptiva y no como evaluación independiente de una dimensión seleccionada. La cercanía entre F1 de validación y prueba no prueba ausencia de sesgo. La selección de dimensión por F1 usa etiquetas de spam: las densidades son de una clase, pero todo el procedimiento no es enteramente no supervisado. El cuantil de ham reservado fija una fracción objetivo en calibración y no garantiza esa tasa en datos futuros. El número total de ham tampoco garantiza que cada intervalo de las colas esté bien poblado.

9.3. Experimento adicional reproducible

La celda opcional posterior al punto 2 conserva las constantes vigentes. Compara la cuadrícula de regresión con su ampliación a tasa 100 y 8000 épocas. Para el detector compara $D = 384$, $D = 2$ vigente y una selección interna de $D \in \{384, 192, 2\}$, intervalos $\{15, 30, 60\}$ y cuantiles $\{0.01, 0.025, 0.05, 0.1\}$. Cada alternativa se selecciona exclusivamente con el entrenamiento de su corrida. También cuenta textos idénticos compartidos por entrenamiento y prueba y calcula un F1 diagnóstico sobre textos no vistos. Ese subconjunto no equivale a una partición agrupada ni cuantifica por sí solo el sesgo por duplicados. Las alternativas son exploratorias: se diseñaron después de conocer los resultados previos del mismo dataset y no sustituyen una evaluación nueva. La persona autorizó estas corridas con la caché local y sin descargas.

Resultados de las 30 corridas por variante.

Variante	Tasa de aciertos	F1
Regresión vigente	0.9906 ± 0.0016	0.9641 ± 0.0063
Regresión, cuadrícula ampliada	0.9904 ± 0.0018	0.9636 ± 0.0068
Histogramas, $D = 384$	0.7892 ± 0.0119	0.0386 ± 0.0145
Histogramas, $D = 2$ vigente	0.9195 ± 0.0084	0.7043 ± 0.0247
Histogramas, calibración por corrida	0.9321 ± 0.0061	0.7173 ± 0.0441

La ampliación de la regresión mejora F1 en 2 corridas, empata en 22 y empeora en 6: diferencia pareada -0.0005 ± 0.0023. Se conserva la cuadrícula vigente. El detector calibrado mejora en 24 y empeora en 6, con diferencia $+0.0130 \pm 0.0519$. Elige siempre $D = 2$, cuantil 1 % o 2.5 % en 27 corridas y 5 % en 3. Reduce los ham marcados de 70.5 a 35.4 por prueba, pero aumenta el spam escapado de 64.0 a 78.1 y la desviación de F1 de 0.0247 a 0.0441. Su F1 medio de validación es 0.7480 y el de prueba 0.7173; no se adopta automáticamente esa alternativa.

Entre 145 y 181 textos de prueba por corrida ya aparecen en entrenamiento; media 162.2 (9.70 %). El F1 de la regresión vigente sobre textos no vistos es 0.9565 ± 0.0076. Esto no cuantifica el sesgo por duplicados: es un subconjunto distinto y no una partición agrupada. Las tres tablas completas de auditoría se exportan desde la celda opcional a `results/tables/auditoria-*.csv`; la implementación permanece en el notebook, sin copias Python. La celda queda desactivada por defecto; se ejecutó con activación temporal y autorización para estas corridas.

Paquete para el equipo (25/10/2026). La persona confirmó conservar las configuraciones vigentes y mantener las sugerencias documentadas. Se incorpora `scripts/run_puntos_1_2.py`: selecciona las celdas existentes, valida la caché antes de limpiar resultados y usa un kernel nuevo del intérprete invocante. No duplica la implementación del notebook. `-check` no ejecuta experimentos; `-audit` activa las alternativas solo en una copia y `-allow-download` permite regenerar MPNet explícitamente. Se guarda un respaldo local de resultados y el notebook ejecutado en `build/`; el notebook canónico del commit queda sin salidas de desarrollo. La evidencia compartida son los CSV, PNG y ambos PDF revisados. La guía `docs/reproducibility.md` y `requirements-audit.txt` documentan la instalación, las versiones directas observadas y la regeneración de la caché; no se versionan entornos, cachés, pesos de modelos ni archivos privados de la máquina. Tres pruebas nuevas verifican selección, identidad de caché sin modificar resultados y ejecución de una celda mínima con el intérprete correcto. La comprobación local del ejecutor no requirió repetir las corridas largas.

10. Puntos pendientes

El punto 2 está implementado; su conformidad literal requiere resolver la variante de dimensión. Lo que falta, en orden (detalle en `TODO.md`):

1. Validar con el docente si acepta $D = 2$ como variante del apartado 2.1. La referencia con $D = 384$ ya tiene 30 corridas; la persona confirmó mantener la configuración vigente y no adoptar las alternativas.

2. Avisar al equipo que el detector vigente usa 2 componentes y la regresión 384; las constantes no se cambiaron durante la auditoría.

3. Punto 3: elegir modelos, prompt y tratamiento de respuestas ambiguas; LoRA o DoRA como extra. Sus tareas y pruebas se conservan.

4. Completar la comparación de métodos y las conclusiones del informe.

5. Confirmar integrantes y fecha de entrega; después, ejecución final completa, Doxygen, PDF final y `.zip`.

11. Registro de decisiones

Fecha	Decisión	Motivo
17/10/2026	Sigmoide estable y gradiente exacto propio.	Implementación transparente sin desbordamientos ni optimizadores externos.
19/10/2026	Frontera verdadera fija en 1.3.	Comparar la recta aprendida con una referencia con sesgo.
23/10/2026	1.3 independiente de UCI; dataset original versionado.	Evitar mezclar demostración sintética y evaluación real; compartir los mismos datos.
23/10/2026	PCA por SVD centrada y comparación pareada.	Ajuste propio y comparación sobre las mismas particiones.
24/10/2026	Único notebook con toda la implementación.	Sustituye archivos por punto y utilidades separadas; pruebas consumen las mismas definiciones.
24/10/2026	Mantener logística $Xw + b$ seguida de sigmoide.	Confirmación del equipo; coincide con 1.1 y 1.2 del enunciado.
24/10/2026	MPNet con 768 características; descargar y ejecutar 1.4–1.5.	Confirmación del equipo; reemplaza MiniLM/384 y sus resultados.
24/10/2026	Calibración interna por corrida y cantidad de componentes.	Aislar cada prueba y usar el ganador automáticamente.
24/10/2026	Conservar duplicados y documentar su limitación.	Mantener el dataset original y el protocolo por filas sin introducir otra evaluación.
24/10/2026	Fijar inicialmente $D = 384$ para el punto 2 (sustituida después por $D = 2$).	Decisión del equipo: mitad de las características, 96.16 % de varianza descriptiva y F1 medio 0.9637 frente a 0.9641 sin PCA; no implica equivalencia estadística.
24/10/2026	Densidades del punto 2 solo con ham del entrenamiento.	Describir la distribución normal; el spam queda como lo atípico.
24/10/2026	Umbral: cuantil 5 % de un 20 % de ham reservado; 30 intervalos.	Con los ham de los histogramas el umbral queda sesgado hacia arriba (con 384 componentes marcaba 17.3 % de ham en vez de 5 %).
24/10/2026	Detector con $D = 2$; la regresión conserva 384.	Mayor F1 de validación interna en las 30 particiones entre los casos de 1.5; con 384 el spam resulta más verosímil que el ham (F1 0.04).
24/10/2026	2.2: comparar el detector por partición con la regresión sin PCA y con $k = 2$.	Separar el efecto de la dimensión del efecto del método, con las mismas semillas.
24/10/2026	Corregir la derivada de la sigmoide en cero y añadir una prueba.	Autograd daba 0 en vez de 1/4; se conserva el entrenamiento analítico.
24/10/2026	Auditar con caché local; conservar las configuraciones vigentes.	Autorización para 30 corridas por variante, sin descargas. Ampliar la regresión no mejoró F1; calibrar histogramas reduce falsas alarmas, pero aumenta el spam escapado.
24/10/2026	Registrar la diferencia entre $D = 384$ literal y $D = 2$ del equipo.	La mejor métrica no demuestra cumplimiento del enunciado; validar la variante con el docente.

Fecha	Decisión	Motivo
25/10/2026	Conservar las configuraciones del equipo y compartir la reproducción.	Confirmación de la persona; las alternativas siguen documentadas sin adoptarse. Se incluye un ejecutor portátil, dependencias directas y guía; se excluyen cachés, modelos y entornos locales.

12. Verificación y reproducción

- `pytest` y celda de pruebas del notebook: 48 superadas, 1 pendiente (3.1), 0 fallidas. La prueba nueva reprodujo el fallo antes de la corrección y pasa después.
- Notebook guardado validado con `nbformat`, IDs únicos y AST. Las definiciones se cargan sin descargas ni experimentos. Se conservan sesgo, gradiente manual y contratos existentes.
- Dataset original sin modificaciones y caché MPNet verificada por metadatos, hash de textos ordenados, forma $(5574, 768)$, tipo `float32` y finitud. La auditoría no descargó modelos.
- Ejecución desde un kernel nuevo de los puntos 1 y 2, auditoría adicional y pruebas, en 407 segundos. Se conservaron las salidas en una copia local ejecutada; el notebook del commit se limpia según las reglas de desarrollo; la celda opcional de auditoría quedó desactivada para futuras ejecuciones. La ejecución final completa sigue pendiente del punto 3.
- Las métricas de regresión reproducen exactamente las tablas anteriores. Las métricas del detector vigente también coinciden; hay diferencias numéricas pequeñas en umbrales y en validación con $D = 384$ respecto de Linux (tasa de aciertos 0.7812 frente a 0.7810). Se registran los valores de esta ejecución sin atribuirlos a cambios de modelo.
- Las 18 figuras se regeneraron e inspeccionaron visualmente. Los nombres largos de los diagramas de caja ocupan dos líneas y las medianas usan tinta neutra. No se editaron figuras ni tablas experimentales a mano.
- Revisión e informe preliminar compilados mediante los dos comandos `./build_pdf.sh review` y `./build_pdf.sh`; revisión visual de las páginas renderizadas. El punto 3, la comparación global y las conclusiones finales permanecen pendientes.

Para reproducir, instalar `requirements.txt` y ejecutar las definiciones, configuración, datos y puntos 1 y 2 completos del cuaderno. La auditoría requiere activar su celda opcional; se debe autorizar esa ejecución larga. La configuración limpia las exportaciones: regenerar las figuras antes de compilar documentos que las usen.