Trabajo práctico 2: Detección de spam con aprendizaje supervisado y no supervisado

Alejandro Quesada Jose Herrera Manfred Azofeifa

24 de octubre de 2026

Índice

1. Introducción **3**
1.1. Protocolo común . . . 3

2. Aprendizaje supervisado: regresión logística **4**
2.1. Evaluación del modelo . . . 4
2.2. Entrenamiento . . . 4
2.3. Verificación con datos linealmente separables . . . 4
2.4. Extracción de características y clasificación . . . 7
2.5. Reducción de dimensionalidad con PCA . . . 9
2.6. Auditoría de la cuadrícula de entrenamiento . . . 14

3. Detección de anomalías: umbral de verosimilitud **14**
3.1. Densidades por histograma . . . 14
3.2. Evaluación en 30 corridas . . . 18
3.3. Auditoría de dimensión, intervalos y cuantil . . . 20

4. Clasificación supervisada: modelos grandes de lenguaje **21**
4.1. Clasificación sin ajuste . . . 21
4.2. Ajuste fino eficiente . . . 21

5. Pruebas unitarias **21**
5.1. Evaluación del modelo . . . 21
5.2. Entrenamiento . . . 22
5.3. Otras pruebas del punto 1 . . . 22
5.4. Protocolo experimental y caché . . . 23
5.5. Detector de anomalías (punto 2.1) . . . 23
5.6. Ejecución portátil de los puntos 1 y 2 . . . 24

6. Comparación de resultados **24**

7. Conclusiones **24**
7.1. Limitaciones . . . 24

Índice de figuras

1. Datos sintéticos de entrenamiento y frontera verdadera. 5
2. Proceso de entrenamiento sobre los datos sintéticos. 6
   a. Entropía cruzada media en cada época. 6
   b. Frontera $p = 0.5$ tras 0, 10, 50, 200 y 1000 épocas. 6
3. Probabilidad estimada por el modelo final y frontera aprendida sobre los 200 puntos de prueba. 7
4. F1 en la validación interna de la primera corrida. Las demás corridas realizan su propia calibración. 8
5. Resultados de la regresión logística con MPNet en las 30 corridas. 9
   a. Métricas de cada corrida y su media. 9
   b. Matriz de confusión promedio. 9
6. Varianza explicada por componente y acumulada en el PCA descriptivo de todos los mensajes. 10
7. Todos los mensajes sobre las dos primeras componentes del PCA descriptivo. 11
8. Plano de las dos primeras componentes y separación entre clases en cada una de las k componentes conservadas. 12
   a. 50 % de D ($k = 384$). 12
   b. 25 % de D ($k = 192$). 12
9. F1 de las 30 corridas con MPNet, con y sin PCA. 13
10. Brecha de verosimilitud entre ham y spam en la validación interna de la primera partición, con 384 componentes. Arriba, por componente; abajo, acumulada hasta k. 16
11. Densidades de los ham de entrenamiento en las dos componentes principales (semilla 2026). 17
12. Puntajes de verosimilitud de la prueba por clase y umbral (semilla 2026). 17
13. Región que el detector acepta como normal y mensajes de prueba (semilla 2026). . . 18
14. F1 del detector de anomalías y de la regresión logística en las mismas 30 particiones. 19
15. Tasa de aciertos del detector de anomalías y de la regresión logística en las mismas 30 particiones. 20

1. Introducción

Este informe documenta el Trabajo práctico 2 del curso de Principios de Inteligencia Artificial. El trabajo consiste en detectar mensajes spam del dataset SMSSpamCollection [2, 1], un conjunto público de mensajes SMS etiquetados como *ham* o *spam*, con tres enfoques implementados en PyTorch [5]:

1. clasificación supervisada con regresión logística sobre las características de un codificador, con y sin reducción de dimensionalidad por análisis de componentes principales;
2. detección de anomalías con densidades por histograma y un umbral de verosimilitud;
3. clasificación con modelos grandes de lenguaje.

La implementación completa vive en el notebook `tp2_detector_spam.ipynb`, organizado en celdas de definiciones, configuración, experimentos y análisis. Las pruebas externas cargan las mismas definiciones sin ejecutar descargas ni experimentos. Las métricas, figuras y tablas provienen de la ejecución completa de sus secciones; el punto 3 sigue pendiente de implementación.

1.1. Protocolo común

- **Etiquetas.** *ham* $= 0$ y *spam* $= 1$; spam es la clase positiva del F1-score y la anomalía del detector.
- **Métricas.** Tasa de aciertos y F1-score.
- **Particiones.** 30 particiones estratificadas de 70 % de entrenamiento y 30 % de prueba, una por semilla.
- **Muestreo de los modelos de lenguaje.** 30 muestras estratificadas del 30 % del dataset.
- **Codificador.** `sentence-transformers/all-mpnet-base-v2`, con vectores de 768 dimensiones (Sección 2.4).
- **Hiperparámetros de la regresión logística.** Calibrados por F1 en una validación interna de cada corrida, tomada solo de su entrenamiento (Sección 2.4).
- **Dimensión óptima del PCA.** El equipo confirmó $D = 384$ el 24 de octubre de 2026 para la regresión logística, la mitad de las 768 características (Sección 2.5).
- **Detector de anomalías.** Entre los casos de 1.5, el detector de histogramas usa $D = 2$, elegida en una validación interna de los 30 entrenamientos; las densidades se construyen solo con ham y el umbral es el cuantil 5 % de un 20 % de ham reservado (Sección 3). Esta variante difiere de reutilizar $D = 384$, como pide la lectura literal del apartado 2.1; su aceptación debe validarse con el docente.
- TODO: decisiones pendientes del equipo (modelos de lenguaje).

2. Aprendizaje supervisado: regresión logística

2.1. Evaluación del modelo

La regresión logística modela la probabilidad de que un mensaje sea spam como

$$p(y = 1 \mid x) = \sigma(x^\top w + b), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

La función `forward` es una implementación propia en PyTorch [5], sin `torch.nn`. Calcula los logits $z = Xw + b$ de las n muestras con un único producto matriz-vector y les aplica la sigmoide. Para que la sigmoide no se desborde con logits grandes, se evalúa con $e^{-|z|} \in (0, 1]$:

$$\sigma(z) = \begin{cases} \dfrac{1}{1 + e^{-|z|}} & z \geq 0, \\[2ex] \dfrac{e^{-|z|}}{1 + e^{-|z|}} & z < 0. \end{cases}$$

Ninguna de las dos ramas produce infinitos, ni en el valor ni en el gradiente, mientras que la forma directa $1/(1 + e^{-z})$ calcula e^{1000} para $z = -1000$ y su gradiente con Autograd resulta indefinido. Para conservar también $\sigma'(0) = 1/4$, el exponente se implementa seleccionando $-z$ si $z \geq 0$ y z en caso contrario. Usar directamente `abs` daría una derivada nula en cero con Autograd. Una prueba adicional verifica los gradientes de pesos y sesgo en ese punto; el entrenamiento conserva su gradiente analítico propio.

2.2. Entrenamiento

La función `train_logistic_regression` minimiza la entropía cruzada binaria media

$$L(w, b) = -\frac{1}{n} \sum_{i=1}^{n} \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right], \qquad p_i = \sigma(x_i^\top w + b),$$

con descenso del gradiente por lotes completos, también implementado sin optimizadores de PyTorch. En cada época se evalúa p con `forward` y se aplica el gradiente exacto de L:

$$w \leftarrow w - \frac{\alpha}{n} X^\top (p - y), \qquad b \leftarrow b - \frac{\alpha}{n} \sum_{i=1}^{n} (p_i - y_i).$$

Los pesos se inicializan con una normal de desviación 0.01 generada con la semilla de la corrida y el sesgo, en cero, de modo que la misma semilla reproduce el mismo modelo. El entrenamiento ejecuta un número fijo de épocas con una tasa de aprendizaje α fija; cada experimento elige sus propios valores. El historial de pérdida guarda la pérdida inicial y la de cada época, calculada como $\log(1 + e^{z_i}) - y_i z_i$, expresión equivalente a la entropía cruzada que no se indefine cuando p_i vale exactamente 0 o 1.

2.3. Verificación con datos linealmente separables

Antes de usar los mensajes, se verifica el regresor en un caso donde la respuesta correcta se conoce. La frontera verdadera es la recta

$$w^{*\top} x + b^* = 0.6\, x_1 + 0.8\, x_2 - 0.5 = 0.$$

Como $\|w^*\| = 1$, ${w^*}^\top x + b^*$ es la distancia con signo de x a la recta. Cada punto se coloca a una distancia $|d| = 1 + 0.5\,|z|$, con $z \sim \mathcal{N}(0,1)$, del lado de su clase (la clase 1 donde $d > 0$) y a una posición $\mathcal{N}(0, 2^2)$ a lo largo de la recta. Entre las dos clases queda una franja vacía de ancho 2, así que los datos son linealmente separables por construcción. Se generan 200 puntos de entrenamiento (100 por clase) y otros 200 de prueba con otra semilla (Figura 1).

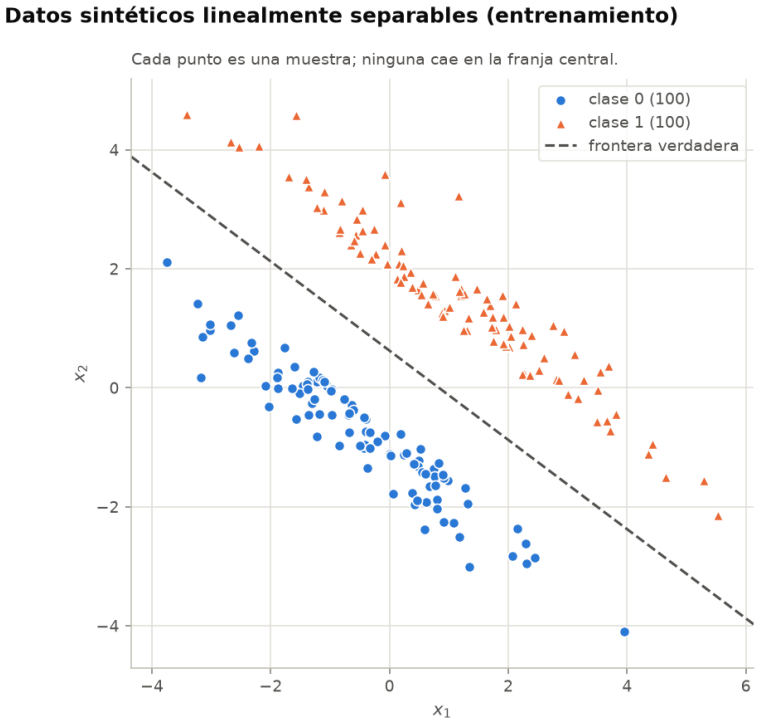
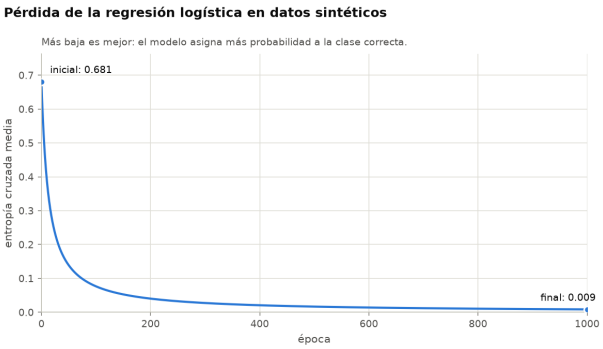
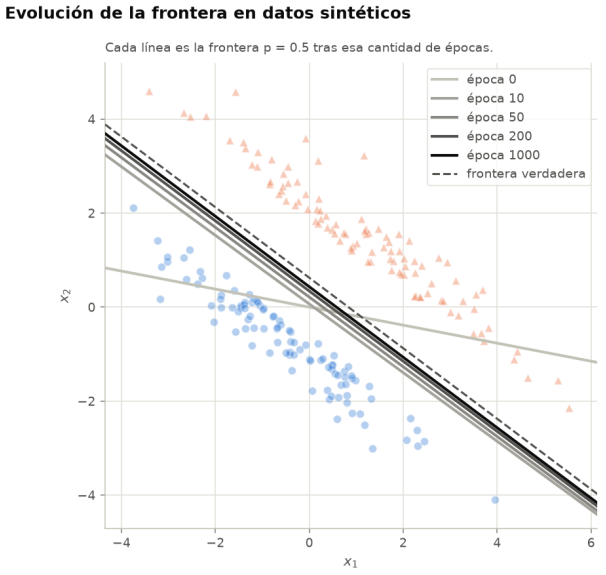


Figura 1: Datos sintéticos de entrenamiento y frontera verdadera.

El modelo se entrena con $\alpha = 0.1$ durante 1000 épocas. Como el entrenamiento es determinista para una semilla dada, entrenar k épocas reproduce exactamente el estado del entrenamiento completo en la época k; así se obtienen las fronteras intermedias de la Figura 2. La Tabla 1 compara cada estado con la frontera verdadera: como la recta $w^\top x + b = 0$ no cambia al multiplicar w y b por una constante, se reportan w y b divididos por $\|w\|$ y el ángulo entre w y w^*.



(a) Entropía cruzada media en cada época.



(b) Frontera $p = 0.5$ tras 0, 10, 50, 200 y 1000 épocas.

Figura 2: Proceso de entrenamiento sobre los datos sintéticos.

Tabla 1: Evolución del entrenamiento en datos sintéticos.

Época	Pérdida	Aciertos (entr.)	$w_1/\|w\|$	$w_2/\|w\|$	$b/\|w\|$	Ángulo con w^*
0	0.681	0.90	0.188	0.982	0.000	26.02°
10	0.388	1.00	0.590	0.808	−0.054	0.73°
50	0.139	1.00	0.596	0.803	−0.172	0.31°
200	0.040	1.00	0.598	0.801	−0.274	0.13°
1000	0.009	1.00	0.600	0.800	−0.347	0.01°
Verdadera	—	—	0.600	0.800	−0.500	0°

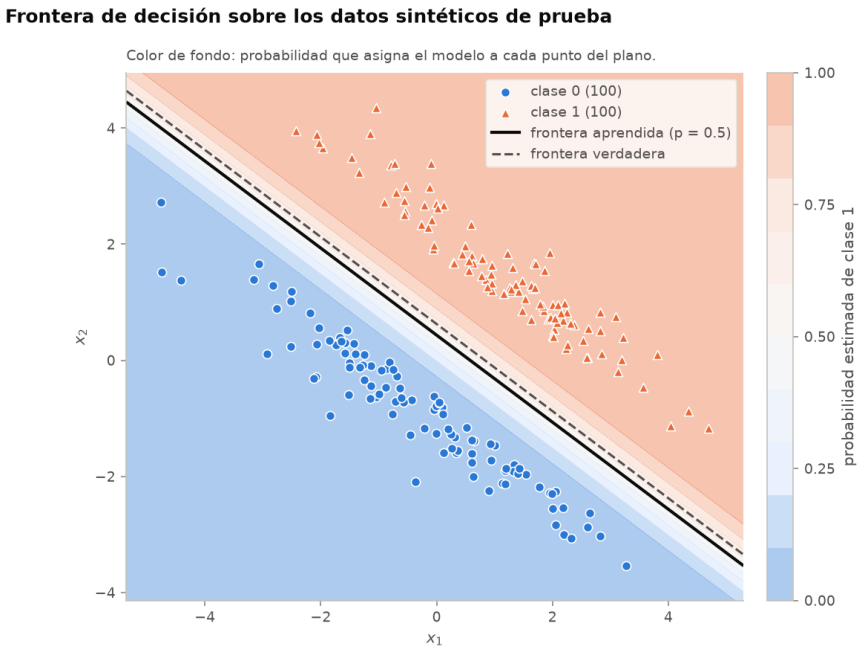


Figura 3: Probabilidad estimada por el modelo final y frontera aprendida sobre los 200 puntos de prueba.

El regresor aprende una frontera separadora casi paralela a la verdadera. En la época 0 los pesos son casi nulos ($\|w\| = 0.02$) y la frontera está girada 26° respecto de la verdadera; tras 10 épocas ya clasifica bien todo el entrenamiento y tras 1000 el ángulo es de 0.01°. La pérdida baja de 0.681 a 0.009 sin oscilar. En los 200 puntos de prueba la tasa de aciertos y el F1-score valen 1 (Figura 3).

Dos detalles muestran cómo aprende la regresión logística con datos separables. Primero, $\|w\|$ crece sin parar (de 0.02 a 3.84): como existe una recta que separa todo, la pérdida se puede seguir reduciendo haciendo más abrupta la transición de probabilidad, sin cambiar la recta; por eso la franja de colores alrededor de la frontera es angosta. Segundo, el sesgo normalizado (-0.35) todavía no alcanza el verdadero (-0.5): la frontera aprendida está desplazada 0.15 hacia la clase 0, pero dentro de la franja vacía, así que clasifica todo bien. Con datos separables hay infinitas rectas que separan perfectamente, y el descenso del gradiente se mueve muy lentamente hacia la de margen máximo [7]: la orientación converge mucho antes que la posición.

2.4. Extracción de características y clasificación

Codificador y datos. El archivo SMSSpamCollection de UCI contiene etiquetas y textos originales; sus columnas no son las dimensiones de entrada del clasificador. Cada mensaje se convierte en un embedding de $D = 768$ dimensiones con `all-mpnet-base-v2`, de sentence-transformers [6]. Se fija la revisión `e8c3b32edf5434bc2275fc9bab85f82640a19130` del modelo[1]. La ejecución produjo una matriz de forma $(5\,574, 768)$, en `float32`, con vectores de norma 1 y sin valores no finitos.

El codificador está preentrenado y no se ajusta con los mensajes de este dataset, por lo que las características se calculan una sola vez. La caché registra el identificador y la revisión del modelo, la dimensión y un hash SHA-256 de los textos ordenados. Antes de reutilizarla se comprueban esos metadatos, la forma y el tipo del tensor; una caché de MiniLM o de otros textos no se acepta. Los

[1] `https://huggingface.co/sentence-transformers/all-mpnet-base-v2`

datos sintéticos, el modelo y los hiperparámetros del apartado 1.3 no participan en este experimento ni en el apartado 1.5.

Calibración interna por corrida. Se realizan 30 particiones estratificadas, con semillas de 2026 a 2055. En cada partición, el 70 % se destina a entrenamiento y el 30 % a prueba; del entrenamiento se reserva un 20 % estratificado para validación interna y el resto ajusta los candidatos. La cuadrícula conserva todas las combinaciones de $\alpha \in \{0.1, 0.5, 1, 2, 5, 10, 20, 50\}$ y $\{250, 500, 1000, 2000, 4000\}$ épocas. Se selecciona automáticamente el mayor F1 en validación y, entre empates, la menor entropía cruzada de validación. Con la combinación elegida se vuelve a entrenar sobre todo el 70 % y solo entonces se evalúa el 30 % de prueba.

Cada corrida vuelve a calibrar: la selección de la primera partición no se reutiliza en las siguientes. De este modo, un mensaje reservado para prueba en una corrida no interviene en la calibración de esa misma corrida. La implementación entrena las tasas en paralelo y evalúa las épocas como checkpoints de sus trayectorias, con la misma inicialización para todos los candidatos; conserva las actualizaciones propias del descenso del gradiente. Una prueba contrasta la cuadrícula vectorizada con entrenamientos independientes.

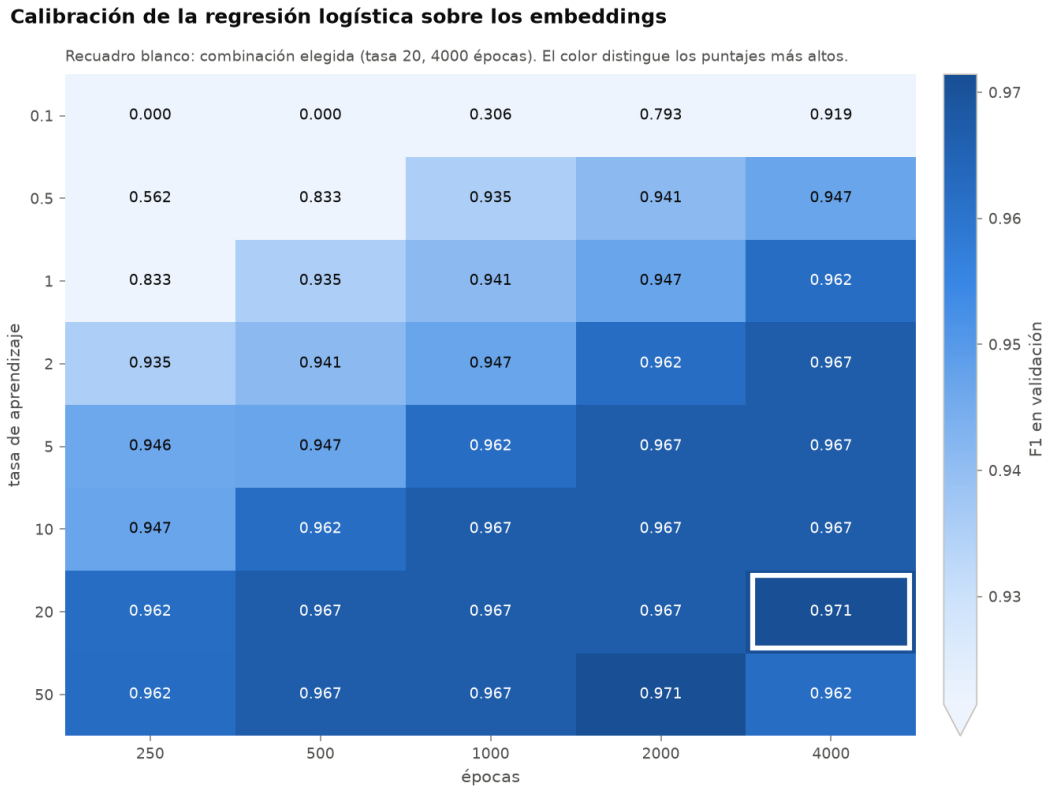


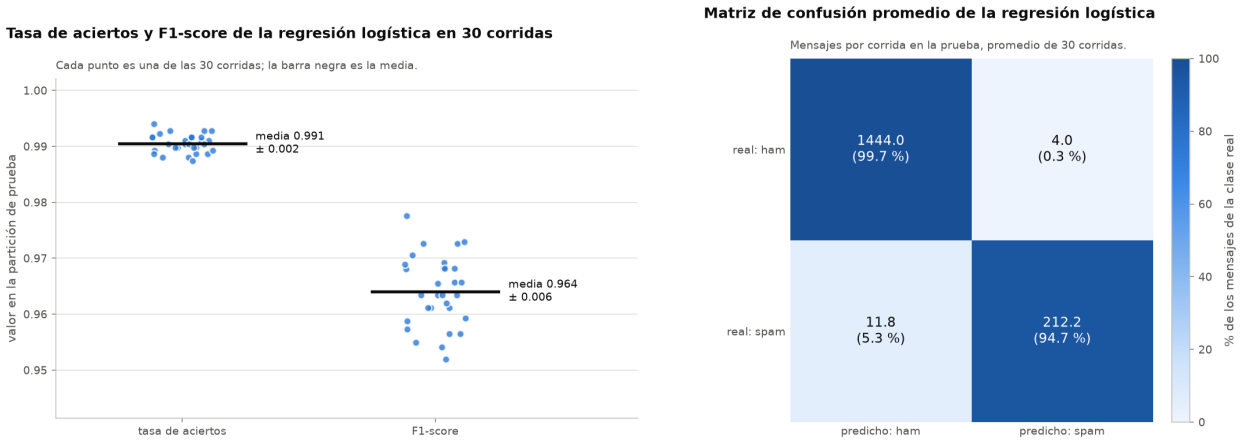
Figura 4: F1 en la validación interna de la primera corrida. Las demás corridas realizan su propia calibración.

En la primera corrida, la validación eligió $\alpha = 20$ y 4000 épocas, con F1 de 0.9714. Las 30 selecciones no fueron iguales: las tasas 10, 20 y 50 aparecieron en 6, 10 y 14 corridas, respectivamente; las épocas variaron entre 500 y 4000. En 15 corridas se seleccionó el máximo de 4000 épocas y en 14 la tasa máxima de 50, por lo que la cuadrícula no demuestra que se haya alcanzado un óptimo fuera de sus límites.

Resultados de las 30 corridas. La prueba de cada partición contiene 1 672 mensajes: 1 448 ham y 224 spam. Se conserva el umbral de probabilidad 0.5 y se registran la tasa de aciertos, el F1 de spam y los conteos de la matriz de confusión. La Tabla 2 resume las métricas y la Figura 5 muestra su dispersión y los errores medios.

Tabla 2: Regresión logística sobre MPNet de 768 dimensiones: 30 corridas con calibración interna en cada partición.

Métrica	Media	Desviación	Mínimo	Máximo
Tasa de aciertos	0.9906	0.0016	0.9874	0.9940
F1-score	0.9641	0.0063	0.9519	0.9776



(a) Métricas de cada corrida y su media.

(b) Matriz de confusión promedio.

Figura 5: Resultados de la regresión logística con MPNet en las 30 corridas.

La tasa de aciertos fue 0.9906 ± 0.0016 y el F1 de spam, 0.9641 ± 0.0063. El F1 varió entre 0.9519 y 0.9776. Las diferencias entre particiones muestran una dispersión acotada en este dataset, aunque no implican independencia estadística de las corridas. Como referencia, un clasificador que predijera siempre ham tendría una tasa de aciertos de $1448/1672 \simeq 0.8660$ y F1 de spam igual a cero. El resultado mejora ambas métricas y el F1 permite valorar la clase minoritaria. En promedio, se marcaron 4.0 ham como spam y se dejaron pasar 11.8 spam por corrida.

Límites de la evaluación. Las 30 particiones reutilizan mensajes del mismo dataset; su desviación describe la variación entre particiones y no es un intervalo de confianza de 30 muestras independientes. Además, la partición se hace por filas, sin agrupar los textos duplicados que existen en el archivo original. Por eso copias del mismo mensaje pueden aparecer en entrenamiento y prueba, con una posible sobreestimación del desempeño sobre mensajes nuevos. El dataset se conserva sin modificar; no se cuantifica el tamaño de ese posible sesgo con esta evaluación.

2.5. Reducción de dimensionalidad con PCA

Método. Con la matriz centrada $X_c = X - \mathbf{1}\mu^\top$ y su descomposición en valores singulares $X_c = U\Sigma V^\top$, las columnas de V son las componentes principales y la varianza de la componente j es

$\sigma_j^2/(n-1)$. La proyección conserva las k primeras: $Z = (X - \mathbf{1}\mu^\top)V_k$. La implementación calcula la SVD en doble precisión con `torch.linalg.svd` y fija el signo de cada componente haciendo positiva su coordenada de mayor valor absoluto. Esto elimina la ambigüedad de signo, aunque no garantiza identidad numérica entre todas las plataformas. Desde $D = 768$ se conservan 384 componentes (50 %), 192 (25 %) y 2.

Calibración y evaluación por dimensión. Cada valor de k y cada corrida tienen su propia selección de tasa y épocas, con la misma cuadrícula y las mismas particiones internas que el caso sin PCA. Durante la calibración, PCA se ajusta exclusivamente con la parte interna de ajuste, sin la validación. Elegidos los hiperparámetros, se ajusta de nuevo con todo el 70 % de entrenamiento y se aplica a la prueba restando esa misma media. Los distintos valores de k reutilizan las primeras componentes del mismo ajuste completo, sin mezclar índices de entrenamiento de otras particiones. Todas las variantes usan las mismas 30 particiones, por lo que las diferencias de F1 se comparan corrida a corrida.

Varianza y visualización. Para las figuras se ajusta un PCA sobre todos los mensajes, exclusivamente descriptivo: ese modelo no se usa para entrenar ni evaluar la clasificación. La Figura 6 muestra la varianza individual y acumulada.

Con 384 componentes se conserva el 96.16 % de la varianza; con 192, el 84.13 %, y con 2, el 8.08 %. Una reducción al 50 % de las coordenadas conserva casi toda la varianza, pero PCA ordena las direcciones por varianza y no por capacidad de separar ham de spam. Por eso esa proporción no sustituye la evaluación de clasificación.

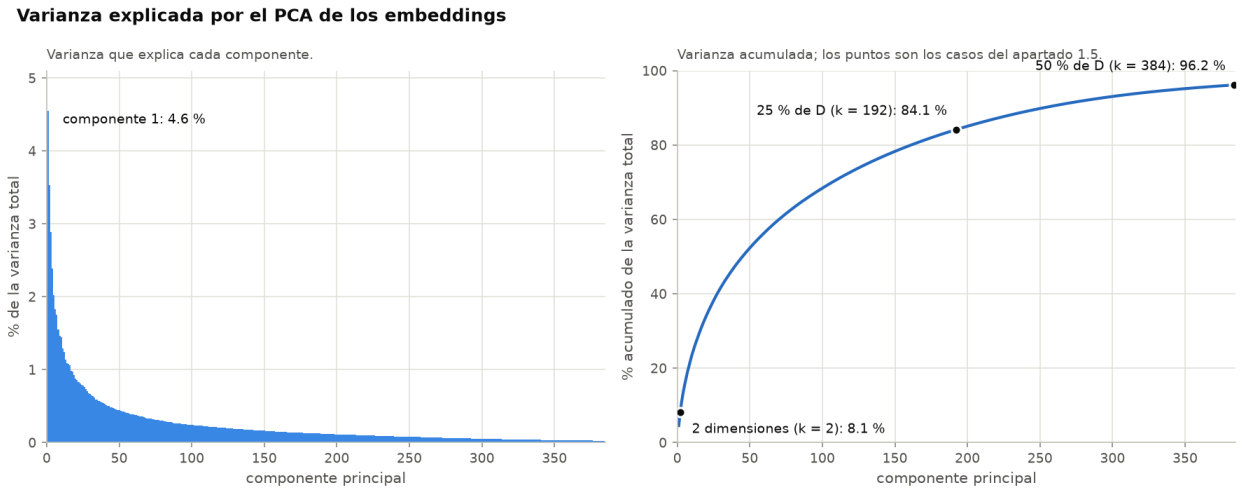


Figura 6: Varianza explicada por componente y acumulada en el PCA descriptivo de todos los mensajes.

Con 2 dimensiones se representan todos los mensajes en el plano (Figura 7). Para 192 y 384, el segundo panel muestra cuánto separan las clases las coordenadas de cada componente, usando

$$|d_j| = \frac{|\bar{z}_{j,\text{spam}} - \bar{z}_{j,\text{ham}}|}{\sqrt{(s^2_{j,\text{ham}} + s^2_{j,\text{spam}})/2}}.$$

Esta medida descriptiva compara la diferencia de medias con la dispersión de las clases y no se usa para elegir componentes o hiperparámetros.

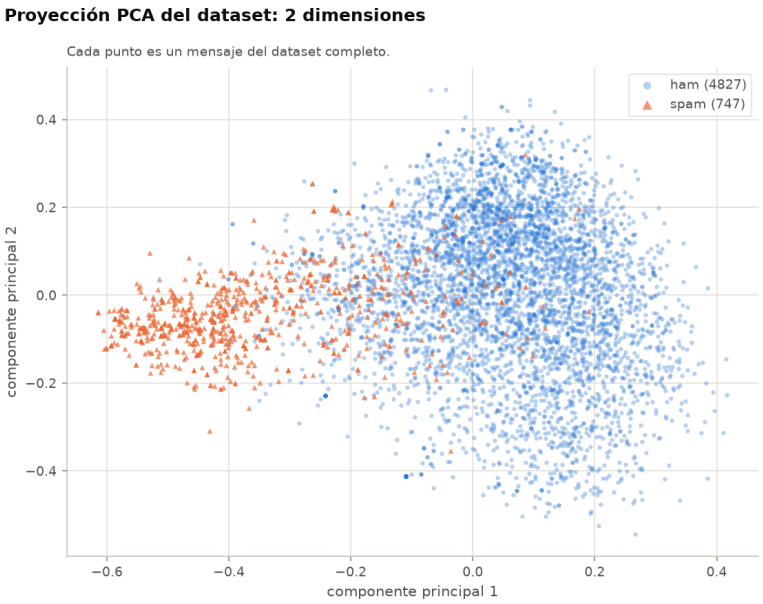
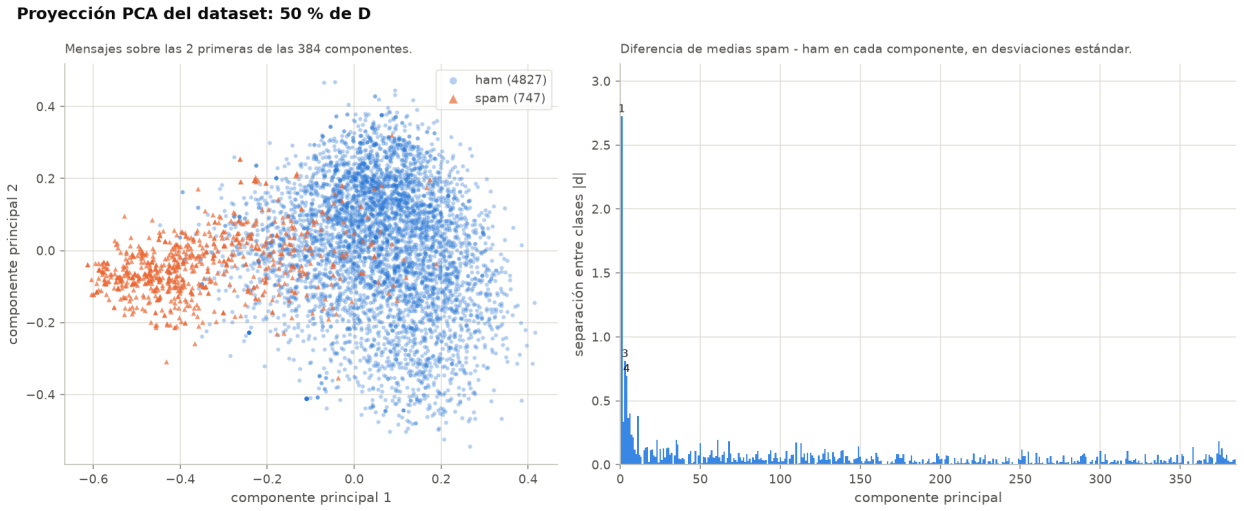
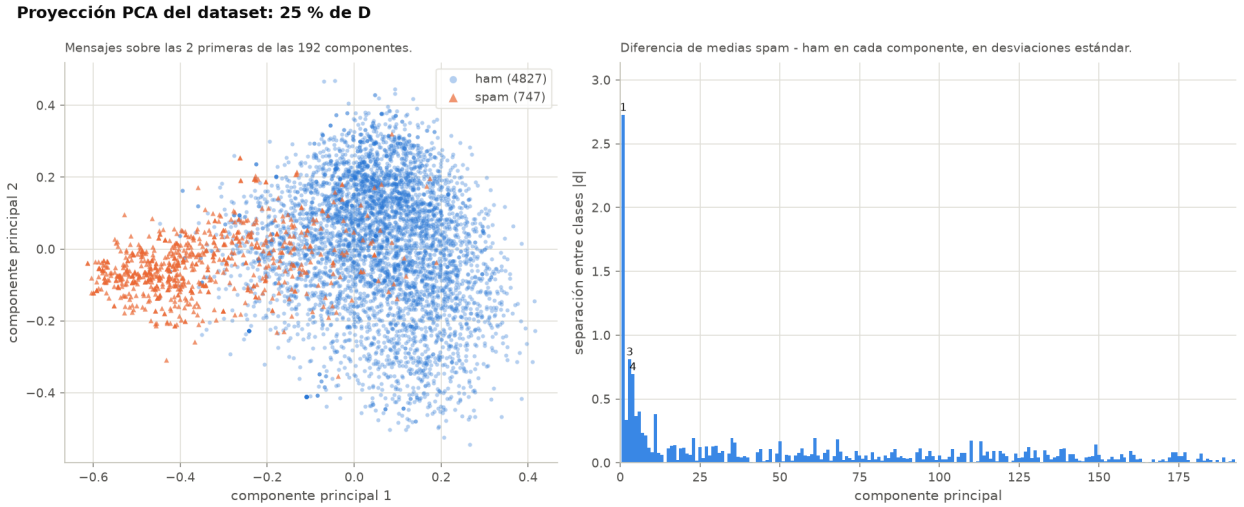


Figura 7: Todos los mensajes sobre las dos primeras componentes del PCA descriptivo.



(a) 50 % de D ($k = 384$).



(b) 25 % de D ($k = 192$).

Figura 8: Plano de las dos primeras componentes y separación entre clases en cada una de las k componentes conservadas.

Clasificación. La Tabla 3 compara las métricas y la diferencia pareada de F1 con respecto al caso sin PCA. La varianza corresponde al PCA descriptivo completo; las métricas proceden de los PCA ajustados de manera independiente dentro de cada corrida.

Tabla 3: Regresión logística con MPNet, con y sin PCA: media ± desviación en 30 corridas. ΔF1 compara cada variante con el caso sin PCA en la misma partición.

Dimensiones	Varianza	Tasa de aciertos	F1-score	ΔF1
768 (sin PCA)	100 %	0.9906 ± 0.0016	0.9641 ± 0.0063	—
384	96.16 %	0.9905 ± 0.0019	0.9637 ± 0.0075	-0.0004 ± 0.0030
192	84.13 %	0.9894 ± 0.0021	0.9596 ± 0.0082	-0.0045 ± 0.0054
2	8.08 %	0.9466 ± 0.0054	0.7845 ± 0.0189	-0.1796 ± 0.0198

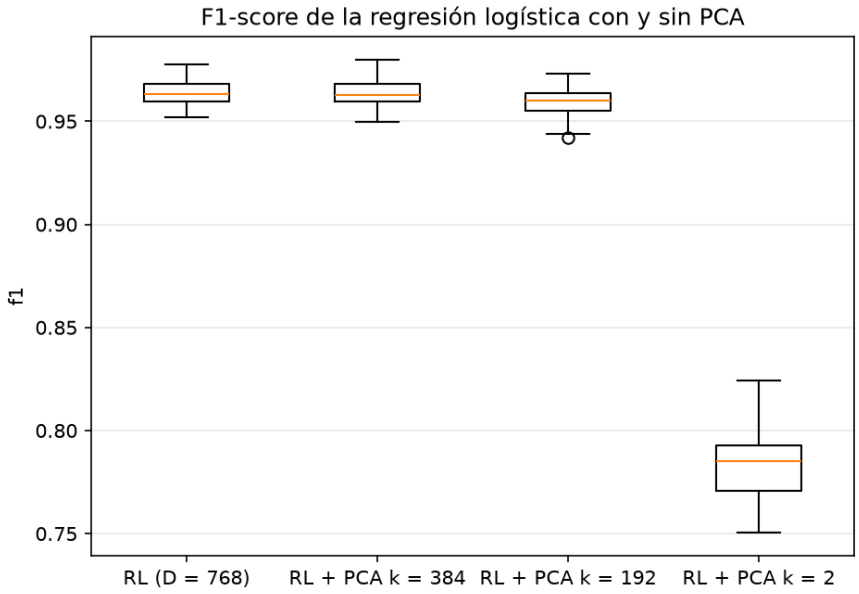


Figura 9: F1 de las 30 corridas con MPNet, con y sin PCA.

Con 384 componentes, el cambio medio de F1 fue de -0.0004, con una desviación pareada de 0.0030; el F1 fue menor que sin PCA en 14 de las 30 corridas. La diferencia media es pequeña y cambia de signo entre particiones, aunque esto no constituye una prueba formal de equivalencia. Con 192 componentes, el cambio fue de -0.0045 ± 0.0054, y el F1 bajó en 24 de las 30 corridas. Con 2 componentes, el cambio fue de -0.1796 ± 0.0198 y el F1 fue menor en las 30 corridas.

El tipo de error también cambia. Sin PCA se marcan en promedio 4.0 ham como spam y se dejan pasar 11.8 spam por corrida. Con 384 componentes, los promedios son 3.9 y 12.1; con 192, 4.3 y 13.4. Con 2 componentes suben a 27.9 y 61.4: se deja pasar alrededor del 27.4 % de los 224 spam de cada prueba. Su tasa de aciertos de 0.9466 esconde una pérdida mayor en la clase minoritaria, que el F1 de 0.7845 hace visible.

Las variantes recibieron calibración interna propia, por lo que se comparan después de buscar sus hiperparámetros en la misma cuadrícula. Esto reduce la dependencia de una configuración única, pero no permite atribuir toda diferencia exclusivamente a información descartada: el resultado también depende de una validación finita y de una búsqueda limitada. En particular, la tasa máxima 50 se eligió en 15 de las corridas con $k = 384$ y en 19 con $k = 192$.

D **óptima.** El equipo confirmó `OPTIMAL_PCA_DIMENSIONS = 384` el 24 de octubre de 2026. Esta elección reduce a la mitad las 768 características y conserva el 96.16 % de la varianza del PCA descriptivo. El F1 medio de 0.9637 queda próximo al 0.9641 del caso sin PCA, con diferencia media pareada de -0.0004; esta cercanía no demuestra equivalencia estadística. Se adopta como compromiso entre reducción de dimensionalidad y clasificación observada para la regresión logística. El detector de histogramas del punto 2 compara estos mismos casos con su propia validación interna y usa 2 componentes (Sección 3). Esta última elección constituye una variante respecto de la lectura literal del apartado 2.1, que pide reutilizar la dimensión óptima del apartado anterior. Su justificación experimental no sustituye la validación de ese alcance con el docente.

2.6. Auditoría de la cuadrícula de entrenamiento

Con las mismas 30 particiones se amplió la cuadrícula a 9 tasas (se agrega 100) y 6 checkpoints (se agrega 8000). Cada corrida seleccionó por F1 y pérdida en su propia validación interna, y volvió a entrenar con todo su entrenamiento. La cuadrícula ampliada obtuvo tasa de aciertos 0.9904 ± 0.0018 y F1 0.9636 ± 0.0068, frente a 0.9906 ± 0.0016 y 0.9641 ± 0.0063 de la vigente. La diferencia pareada de F1 fue -0.0005 ± 0.0023: mejoró en 2 corridas, empató en 22 y empeoró en 6. Aumentar la búsqueda mejoró el F1 medio de validación (0.9680 frente a 0.9673), pero no el de prueba. Se conserva la cuadrícula vigente; alcanzar sus bordes no bastaba para concluir que ampliarla mejoraría la clasificación.

En estas particiones, entre 145 y 181 mensajes de prueba por corrida tienen un texto idéntico en entrenamiento: media 162.2 de 1672 (9.70 %). Sobre los textos de prueba ausentes del entrenamiento, la regresión vigente obtiene F1 0.9565 ± 0.0076. Este diagnóstico describe otro subconjunto, con composición y dificultad propias; su diferencia con el F1 completo no mide por sí sola el sesgo por duplicados. Para evaluarlo haría falta acordar una partición agrupada por texto. El archivo original se conserva íntegro.

3. Detección de anomalías: umbral de verosimilitud

3.1. Densidades por histograma

Modelo. En cada corrida, los mensajes se proyectan con un PCA ajustado solo con el entrenamiento. Para cada componente d se estima una densidad p_d con un histograma de $B = 30$ intervalos de igual ancho entre el mínimo y el máximo observados, normalizado para que integre 1. Las componentes se tratan como independientes y el puntaje de un mensaje $\mathbf{x}$ es

$$s(\mathbf{x}) = \sum_{d=1}^{D} \log p_d(x_d). \tag{1}$$

Un valor en un intervalo vacío o fuera del soporte del histograma recibe la densidad mínima $\varepsilon = 10^{-12}$, de modo que su término vale $\log \varepsilon \approx -27.6$. Un mensaje con $s(\mathbf{x})$ menor que el umbral τ se marca como fuera de la distribución, es decir, como spam.

Decisiones del equipo. Se tomaron el 24 de octubre de 2026:

- **Datos de las densidades.** Solo los ham del entrenamiento. Los histogramas describen la distribución normal y el spam, que no participa, queda como lo atípico.
- **Umbral.** El 20 % de los ham del entrenamiento se reserva y no construye los histogramas. El umbral τ es el cuantil 5 % de los puntajes de esos ham reservados: se acepta marcar como spam alrededor del 5 % de los mensajes normales. Si τ se calculara con los mismos ham de los histogramas, ninguno caería fuera del soporte y el umbral quedaría sesgado hacia arriba frente a datos nuevos. El umbral considera la verosimilitud sumada de todas las densidades, como pide el enunciado.
- **Dimensión.** $D = 2$, elegida entre los casos del apartado 1.5 con una validación interna; se justifica a continuación.

Elección de D. El enunciado pide usar la D óptima deducida en el apartado anterior. En 1.5 se compararon 384, 192 y 2 componentes, y 384 fue el compromiso adoptado para la regresión logística (Sección 2). Ese óptimo depende del modelo, así que los mismos tres casos se compararon con el detector de histogramas en las validaciones internas. En cada una de las 30 particiones se separó la validación interna de 1.4 (20 % estratificado del entrenamiento). Con el resto se ajustaron el PCA y el detector, y este se evaluó en la validación. La Tabla 4 resume el resultado.

Alcance frente al enunciado. Usar $D = 2$ es una decisión del equipo que favorece al detector, pero difiere de reutilizar $D = 384$, la dimensión adoptada en 1.5. Queda pendiente acordar con el docente si se acepta esa variante. La auditoría adicional conserva ambos casos para hacer visible la diferencia; las métricas de $D = 2$ no sustituyen las de $D = 384$.

Alcance de la selección. Cada validación excluye la prueba de su propia corrida, pero las particiones se solapan: una fila de prueba puede participar en la validación de otra corrida. Por ello agregar las 30 validaciones para decidir una única D no aísla globalmente las 30 pruebas de esa decisión. Aquí $D = 2$ gana en todas las validaciones, de modo que elegir D separadamente en cada corrida da la misma dimensión observada. Esto no demuestra ausencia de sesgo de desarrollo ni equivalencia con datos nuevos. Las densidades se ajustan con ham; la selección de D por F1 sí usa etiquetas de spam de entrenamiento. El procedimiento completo no es enteramente no supervisado.

Tabla 4: Detector de anomalías en la validación interna de los 30 entrenamientos: media ± desviación. La última columna cuenta las particiones en que cada D obtiene el mayor F1.

D	Tasa de aciertos	F1-score	Spam detectado	Ham marcado	Gana
384	0.7812 ± 0.0141	0.0401 ± 0.0193	3.4 %	10.3 %	0
192	0.8425 ± 0.0072	0.0237 ± 0.0191	1.4 %	2.9 %	0
2	0.9201 ± 0.0106	0.7085 ± 0.0318	72.1 %	4.9 %	30

Con 384 o 192 componentes el detector casi no encuentra spam; con 2 obtiene el mayor F1 en las 30 particiones. La Figura 10 explica la diferencia. Para cada componente se calcula la media de $\log p_d$ de los ham menos la de los spam de la validación: un valor positivo indica que el spam cae en zonas de menor densidad. En la componente 1 esa brecha es 12.8: es la dirección que separa las clases. En cambio, en 330 de las 384 componentes es negativa, porque el spam está más concentrado que el ham, cerca de la moda de cada histograma, y recibe más densidad. La suma acumulada, que es la diferencia media de puntajes de un detector con k componentes, vale $+12.6$ con 2, se vuelve negativa desde 169, vale -2.8 con 192 y -41.1 con 384. Al sumar cientos de componentes poco informativas, sus aportes pequeños pero sistemáticos superan la señal de las primeras y el spam termina pareciendo más normal que el ham. La suma alcanza su máximo, 14.2, con 11 componentes; ese valor no se consideró porque el equipo restringió sus candidatos a los tres casos ensayados en 1.5. El enunciado no prescribe esa cuadrícula de búsqueda para el detector: pide reutilizar la dimensión óptima anterior.

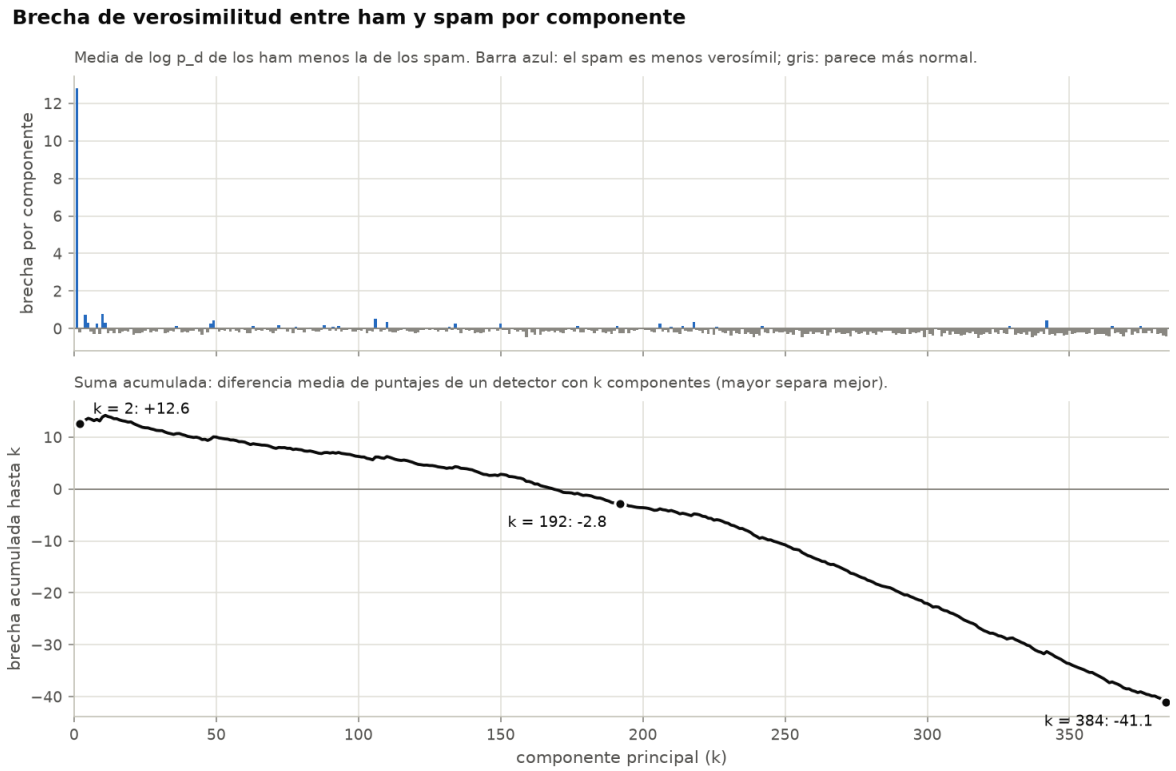


Figura 10: Brecha de verosimilitud entre ham y spam en la validación interna de la primera partición, con 384 componentes. Arriba, por componente; abajo, acumulada hasta k.

Por eso el detector usa $D = 2$ (`ANOMALY_PCA_DIMENSIONS`), mientras que la regresión conserva su óptimo de 384. Dos componentes retienen solo el 8.08 % de la varianza, pero un detector por verosimilitud no necesita reconstruir los datos: necesita las direcciones donde el spam se sale de lo normal, y aquí casi toda esa señal está en la primera componente. La regresión logística puede asignar pesos pequeños a las componentes poco útiles; el detector, en cambio, suma con el mismo peso todas las que recibe.

Densidades estimadas. La Figura 11 muestra los histogramas de la partición de la semilla 2026. De sus 3379 ham de entrenamiento, 2703 construyen los histogramas y 676 fijan el umbral, que queda en $\tau = -0.8334$. Ambas componentes son unimodales, con la mayor parte de la masa entre -0.2 y 0.3 y colas hacia valores negativos; no son exactamente simétricas ni gaussianas. Con unos 2700 ham por componente, los 30 intervalos describen la forma observada, aunque las colas pueden tener intervalos escasos o vacíos; el tamaño total no garantiza estabilidad en cada intervalo.

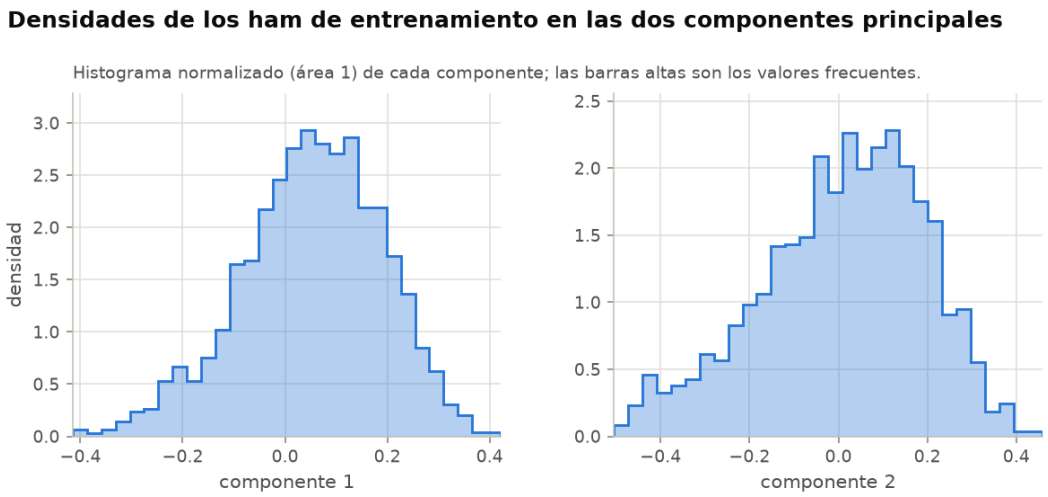


Figura 11: Densidades de los ham de entrenamiento en las dos componentes principales (semilla 2026).

Puntajes y región normal. En la prueba de esa partición (Figura 12), el 4.4 % de los ham queda bajo el umbral, cerca del 5 % buscado, y también el 75.9 % del spam. El pico cercano a −27 corresponde a mensajes fuera del soporte de algún histograma: es el 50 % del spam, a la izquierda de todos los ham en la componente 1, y solo el 0.2 % del ham. Otro 25.9 % del spam cae dentro del soporte, pero en zonas de baja densidad. La Figura 13 muestra la región que el detector acepta como normal. Como las densidades son histogramas independientes, es una unión de rectángulos alrededor del grupo de ham. El spam que se escapa (24.1 %) se mezcla con el ham en el centro del plano: en estas dos componentes no se distingue de un mensaje normal, y ningún umbral de verosimilitud lo separaría sin marcar también muchos ham. En esta partición la tasa de aciertos es 0.9294 y el F1, 0.7424; la evaluación en 30 corridas se presenta en la Sección 3.2.

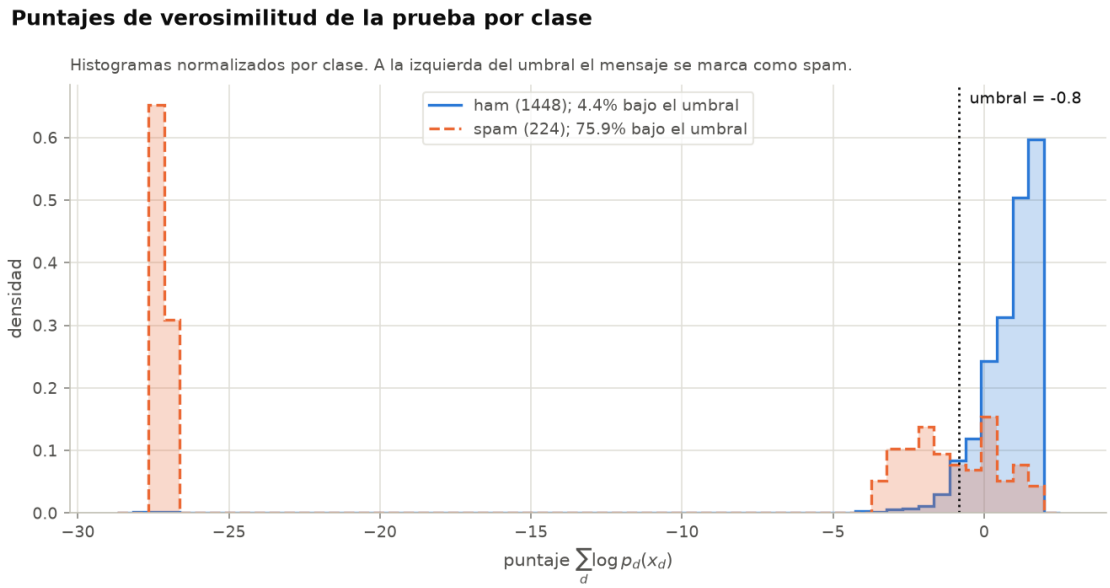


Figura 12: Puntajes de verosimilitud de la prueba por clase y umbral (semilla 2026).

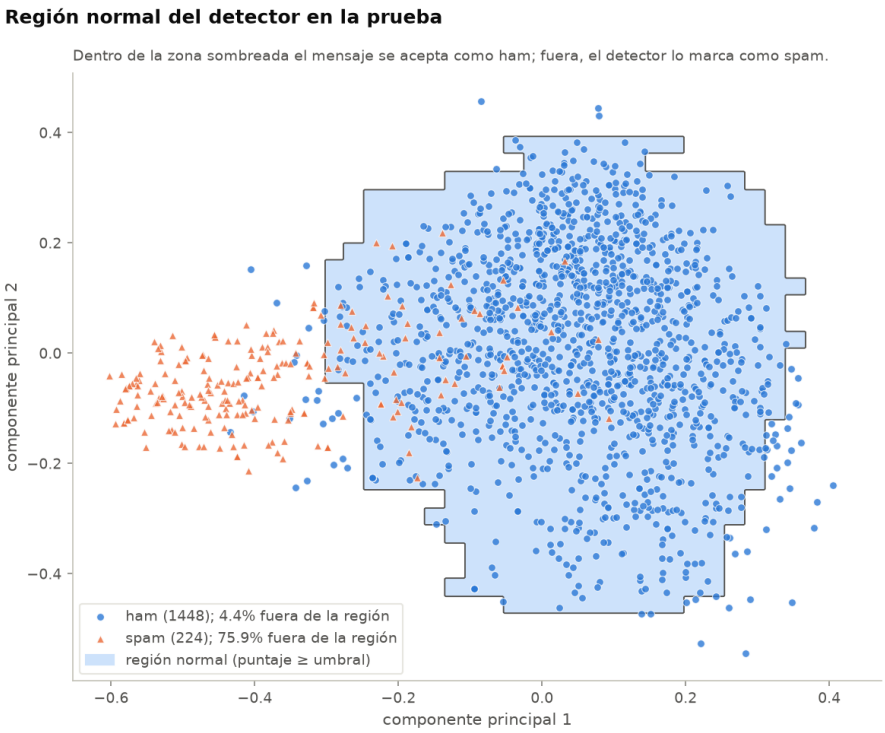


Figura 13: Región que el detector acepta como normal y mensajes de prueba (semilla 2026).

3.2. Evaluación en 30 corridas

El detector se evaluó en las mismas 30 particiones estratificadas 70/30 (semillas 2026 a 2055) que la regresión logística del punto 1. En cada una, el PCA, los histogramas y el umbral se ajustan solo con el entrenamiento y el detector se aplica una vez a la prueba. La Tabla 5 lo compara con la regresión completa y con la regresión que usa las mismas 2 componentes.

Tabla 5: Detector de anomalías y regresión logística en las mismas 30 particiones: media ± desviación de las métricas y errores promedio por prueba (1448 ham y 224 spam).

Método	Tasa de aciertos	F1-score	Ham marcado	Spam escapado	Spam detectado
Regresión, 768 dim.	0.9906 ± 0.0016	0.9641 ± 0.0063	4.0	11.8	94.7 %
Regresión, PCA $k = 2$	0.9466 ± 0.0054	0.7845 ± 0.0189	27.9	61.4	72.6 %
Histogramas, $D = 2$	0.9195 ± 0.0084	0.7043 ± 0.0247	70.5	64.0	71.4 %

En cada partición, el F1 del detector es menor que el de la regresión sin PCA, con una diferencia media de -0.2597 ± 0.0253, y menor que el de la regresión con 2 componentes, con -0.0802 ± 0.0212; en ambos casos ocurre en las 30 corridas. La tasa de aciertos baja 0.0710 y 0.0271, respectivamente. La Figura 14 muestra la distribución del F1 de todos los métodos.

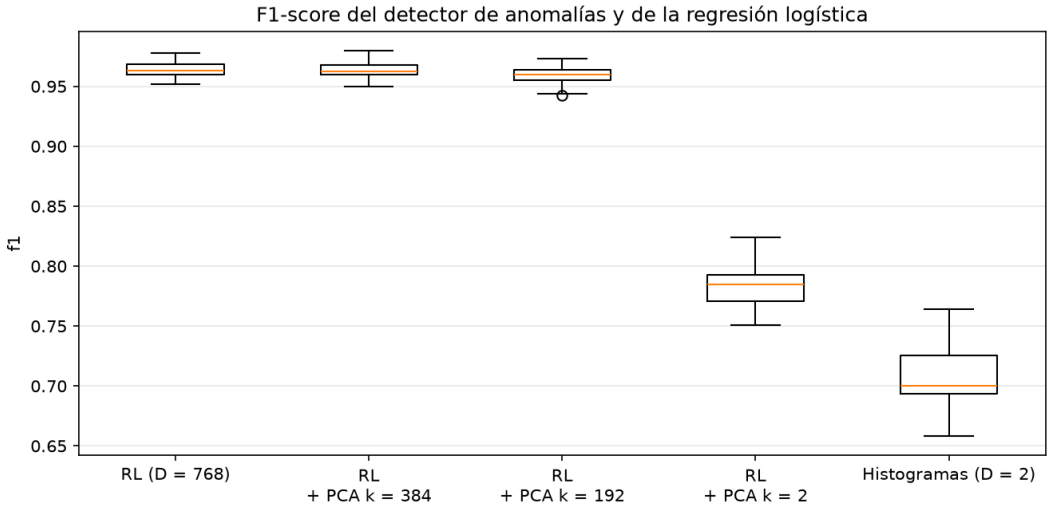


Figura 14: F1 del detector de anomalías y de la regresión logística en las mismas 30 particiones.

Validación y prueba. El F1 en la validación interna con la que se eligió D fue 0.7085 ± 0.0318 y en la prueba es 0.7043 ± 0.0247. La cercanía es descriptiva y no prueba que la selección no sobreestime el desempeño.

Con la misma información, la diferencia está en el ham. Frente a la regresión con 2 componentes, el detector encuentra casi la misma fracción de spam (71.4 % contra 72.6 %). La figura muestra spam mezclado con ham en el plano (Figura 13); los conteos agregados no permiten afirmar que ambos métodos fallen sobre los mismos mensajes. La diferencia son los falsos positivos: 70.5 ham marcados por prueba (4.9 %) contra 27.9 (1.9 %). El umbral apunta al 5 % de los ham de calibración, y el detector, que nunca ve spam, marca los ham poco frecuentes en cualquier dirección. La regresión conoce dónde está el spam y solo marca hacia ese lado. Por eso la precisión del detector es de 0.70.

La dimensión explica la mayor parte de la brecha. Reducir de 768 a 2 componentes le cuesta a la regresión 0.18 de F1; cambiar la regresión por el detector en esas 2 componentes cuesta 0.08 más. El detector no puede aprovechar más componentes porque, al sumar cientos de densidades, el spam parece más normal que el ham (Sección 3).

Tasa de aciertos y variabilidad. Con 86.6 % de ham, clasificar todo como ham ya da una tasa de aciertos de 0.866, así que el 0.92 del detector es una mejora modesta; el F1 refleja mejor el costo en la clase spam (Figura 15). El F1 del detector varía entre 0.658 y 0.764, con una desviación cuatro veces mayor que la de la regresión completa. El umbral cambia entre -1.03 y -0.49 según la partición, pero la fracción de ham marcados se mantiene en 4.9 ± 1.0 %, cerca del 5 % fijado.

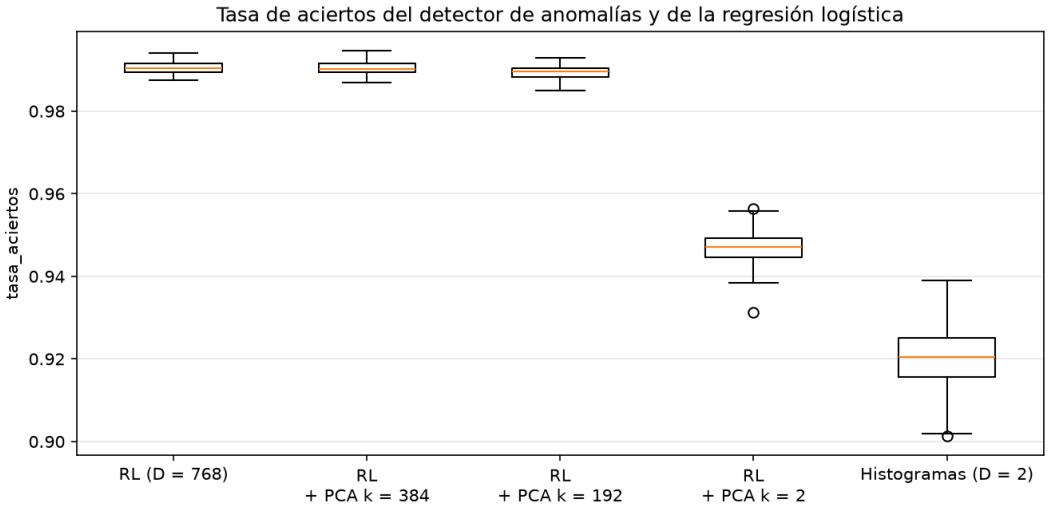


Figura 15: Tasa de aciertos del detector de anomalías y de la regresión logística en las mismas 30 particiones.

Conclusión. El detector no supera a la regresión logística en ninguna partición. Su ventaja es otra: se entrena sin ejemplos de spam y permite fijar una fracción objetivo de ham marcado en la calibración, lo que sería útil si no hubiera spam etiquetado. Con etiquetas disponibles, como en este dataset, el modelo supervisado es claramente mejor. El cuantil empírico no garantiza el mismo porcentaje en datos futuros; los empates, el tamaño de la reserva y los cambios de distribución lo afectan.

3.3. Auditoría de dimensión, intervalos y cuantil

Se ejecutaron otras 30 corridas por variante, con las mismas semillas. La referencia $D = 384$ usa los 30 intervalos y el cuantil 5 % vigentes. La alternativa calibrada elige, dentro del entrenamiento de cada corrida, $D \in \{384, 192, 2\}$, intervalos $\{15, 30, 60\}$ y cuantiles $\{0.01, 0.025, 0.05, 0.1\}$. Se maximiza el F1 de validación; los empates se resuelven por mayor tasa de aciertos y después menor dimensión, número de intervalos y cuantil. El PCA interno excluye la validación; el PCA final y las densidades excluyen la prueba. La Tabla 6 presenta medias y desviaciones entre las 30 particiones.

Tabla 6: Referencias y alternativa del detector. Los errores son promedios por prueba; las constantes oficiales permanecen sin cambios.

Variante	Tasa de aciertos	F1	Ham marcado	Spam escapado
$D = 384$, referencia	0.7892 ± 0.0119	0.0386 ± 0.0145	135.5	216.9
$D = 2$, vigente	0.9195 ± 0.0084	0.7043 ± 0.0247	70.5	64.0
Calibrada por corrida	0.9321 ± 0.0061	0.7173 ± 0.0441	35.4	78.1

La alternativa elige $D = 2$ en las 30 corridas. Elige cuantil 1 % o 2.5 % en 27 y 5 % en 3; no conserva siempre la fracción objetivo vigente. Su F1 mejora en 24 corridas y empeora en 6, con diferencia pareada $+0.0130 \pm 0.0519$. Reduce aproximadamente a la mitad los falsos positivos, pero deja escapar 14.1 spam más por prueba y aumenta la dispersión de F1. El F1 medio de validación es 0.7480 frente a 0.7173 en prueba: ampliar la selección también puede sobreajustar una validación

finita. No se adopta automáticamente: el equipo debe decidir si acepta ese intercambio y el uso de etiquetas de validación para elegir intervalos y cuantil.

La referencia $D = 384$ hace explícito el resultado de reutilizar la dimensión de 1.5, aun cuando sea desfavorable. Las alternativas se investigaron después de conocer resultados previos de este dataset: son evidencia exploratoria, no una validación independiente ni una garantía de mejora en mensajes nuevos.

4. Clasificación supervisada: modelos grandes de lenguaje

4.1. Clasificación sin ajuste

TODO (puntos 3.1 y 3.2): describir los modelos y el prompt, y reportar y comentar las métricas sobre las 30 muestras del 30 %.

4.2. Ajuste fino eficiente

TODO (punto 3.3, extra): describir el ajuste con LoRA [3] o DoRA [4] y analizar sus resultados.

5. Pruebas unitarias

El enunciado exige al menos dos pruebas unitarias para `forward` y dos para `train_logistic_regression`. Las pruebas están en `tests/test_punto1.py` y se ejecutan en la sección "Pruebas unitarias" del notebook y con `pytest`. Cada prueba es una función documentada con Doxygen que falla mediante `assert` o `torch.testing.assert_close` si el resultado no coincide con el esperado.

La implementación que se prueba vive en el mismo notebook. El cargador `tests/notebook_loader.py` ejecuta únicamente las celdas cuyo prefijo es `# Definiciones:`; excluye la configuración, la descarga de modelos y las corridas experimentales. Así las pruebas verifican las funciones entregadas en el cuaderno sin mantener una copia separada en archivos por punto. Las pruebas de estructura comprueban que el notebook sea válido, que no importe el antiguo paquete y que las definiciones no se dupliquen. La última ejecución de `pytest` dio 48 pruebas superadas, 1 pendiente y ninguna fallida; la pendiente corresponde al punto 3.1.

5.1. Evaluación del modelo

`test_forward_zero_parameters_returns_one_half`

Evalúa cinco muestras aleatorias en $\mathbb{R}^3$ con $w = 0$ y $b = 0$. El logit es 0 para cualquier entrada y $\sigma(0) = 0.5$, así que todas las probabilidades deben valer 0.5. La prueba verifica además que la salida tenga forma $(5,)$, una probabilidad por muestra.

`test_forward_matches_sigmoid_and_is_stable`

Con $X = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ -1 & -1 \end{pmatrix}$, $w = (0.5, -1)$ y $b = 0.25$, los logits son -1.25, 0.25 y 0.75; las probabilidades se comparan con $1/(1 + e^{-z})$ calculado con la biblioteca estándar de Python. Luego evalúa logits de ± 1000: la salida debe valer 1 y 0 y el gradiente respecto de w debe ser finito. Verifica la fórmula y la estabilidad numérica; la forma directa de la sigmoide no supera esta prueba porque su gradiente resulta indefinido.

Una tercera prueba de `forward`, `test_forward_gradient_at_zero_matches_sigmoid_derivative`, comprueba $\partial p/\partial w = x/4$ y $\partial p/\partial b = 1/4$ con logit cero. Reprodujo una derivada nula en la versión anterior y pasa con la selección explícita de la rama del exponente.

5.2. Entrenamiento

`test_train_follows_cross_entropy_gradient`
Sobre 200 puntos en $\mathbb{R}^3$ con clases que se traslapan, compara el primer paso del entrenamiento con $w_1 = w_0 - \alpha \nabla_w L(w_0)$ y $b_1 = b_0 - \alpha\, \partial L/\partial b$, donde el gradiente de referencia se obtiene con Autograd sobre `binary_cross_entropy_with_logits` de PyTorch, independiente de la fórmula cerrada que usa la implementación. También comprueba que la pérdida inicial registrada coincida con la de referencia y que, en 50 épocas, la pérdida no aumente en ninguna época y termine por debajo de la inicial. Una implementación que no promedie el gradiente entre las muestras no supera esta prueba.

`test_train_separates_linearly_separable_data`
Entrena sobre seis puntos en dos grupos separables por una recta y verifica que el modelo clasifique correctamente todos los puntos. Entrena una segunda vez con la misma semilla y verifica que los pesos y el sesgo sean exactamente iguales, es decir, que el entrenamiento sea reproducible.

5.3. Otras pruebas del punto 1

Además de las cuatro pruebas obligatorias, `tests/test_punto1.py` verifica el resto del punto 1 sin descargar datos ni modelos:

`test_make_linearly_separable_shapes_and_reproducibility`
El generador de 1.3 devuelve las formas y tipos del contrato, las dos clases balanceadas, todos los puntos a una distancia de al menos el margen de la frontera verdadera y del lado de su clase, y los mismos datos con la misma semilla.

`test_extract_features_keeps_order_and_contract`
Con un codificador falso, `extract_features` devuelve un tensor `float32` de forma (n, D) en el orden de los textos.

`test_grid_search_covers_grid_and_orders_by_score`
La calibración prueba todas las combinaciones, deja primero la de mayor puntaje y resuelve los empates con la menor pérdida en validación.

`test_boundary_plots_return_figures`, `test_run_plots_return_figures`
Las siete gráficas de 1.3 y 1.4 devuelven una figura con el título pedido, sin mostrarla.

`test_fit_pca_recovers_dominant_direction`
Con 500 puntos en $\mathbb{R}^3$ alargados sobre la dirección $(0.6, 0.8, 0)$ y desplazados del origen, la primera componente debe coincidir con esa dirección (salvo el signo) y explicar más del 99 % de la varianza; la media debe ser la de los datos y las componentes, ortonormales y ordenadas de mayor a menor varianza.

`test_transform_pca_matches_explained_variance`
Los datos de ajuste proyectados deben quedar centrados y sin correlación, con la varianza explicada de cada componente en la diagonal de su covarianza; las fracciones de varianza

deben sumar 1 con todas las componentes; la media del ajuste se debe proyectar en el origen, y ajustar dos veces debe dar exactamente las mismas componentes.

`test_pca_plots_return_figures`
: Las gráficas de varianza explicada y de proyección (con 2 y con más componentes) devuelven una figura con el título pedido y la cantidad de paneles esperada.

5.4. Protocolo experimental y caché

Las cuatro pruebas de `tests/test_experiment_protocol.py` usan tensores pequeños y reproducibles, sin descargar modelos ni datos:

1. Comparan todos los candidatos de una cuadrícula vectorizada con entrenamientos independientes, incluyendo el estado inicial y varios checkpoints. Verifican F1 y pérdidas de ajuste y validación.

2. En dos semillas comprueban que el ajuste y la validación interna pertenecen al entrenamiento de esa corrida, que son disjuntos y que excluyen la prueba. También verifican que el entrenamiento final use la tasa y las épocas del candidato ganador.

3. Comprueban que el PCA interno se ajuste sin validación ni prueba, que el PCA final use solo el entrenamiento completo y que distintos valores de k reutilicen únicamente ajustes con los mismos índices.

4. Rechazan cachés antiguas o incompatibles por orden de los textos, identificador o revisión del modelo, forma, tipo o valores no finitos.

5.5. Detector de anomalías (punto 2.1)

Las quince pruebas de `tests/test_punto2.py` usan tensores pequeños construidos a mano:

- **Histogramas.** Cada densidad integra 1; los bordes internos pertenecen al intervalo de la derecha y el máximo se cuenta en el último; una columna constante recibe un soporte de ancho positivo y puntajes finitos.

- **Verosimilitud.** El puntaje es la suma de los logaritmos de las densidades marginales y coincide con la suma de los términos por dimensión; los intervalos vacíos y los valores fuera del soporte, por ambos lados, usan la densidad mínima sin recortar los valores.

- **Umbral.** El cuantil se interpola linealmente; con empates, la regla estricta puede marcar menos de la fracción pedida. El detector construye los histogramas y fija el umbral con filas normales disjuntas, y es reproducible con la misma semilla.

- **Selección y diagnóstico.** Cada candidato usa sus primeras k columnas; cambiar el spam de ajuste no cambia el detector, porque solo los ham construyen las densidades. La brecha por componente es positiva donde el spam cae en zonas de baja densidad.

- **Validaciones y figuras.** Se rechazan datos vacíos, mal formados o no finitos, cantidades de intervalos y cuantiles inválidos; las cuatro figuras devuelven su título como `suptitle`.

5.6. Ejecución portátil de los puntos 1 y 2

Tres pruebas adicionales comprueban que el ejecutor compartido seleccione los puntos 1 y 2 y las pruebas sin modificar la configuración original, que valide la caché sin tocar resultados existentes y que ejecute una celda mínima en un kernel limpio del mismo intérprete invocante. No descargan modelos ni ejecutan experimentos largos. El procedimiento para otras computadoras se describe en `docs/reproducibility.md`.

6. Comparación de resultados

TODO: comparar todos los métodos con la tabla y los diagramas de caja de la sección "Comparación de resultados" del notebook.

7. Conclusiones

TODO: conclusiones del trabajo.

7.1. Limitaciones

TODO: limitaciones del protocolo y de los modelos.

Referencias

[1] Tiago A. Almeida and José María Gómez Hidalgo. SMS spam collection. UCI Machine Learning Repository, `https://archive.ics.uci.edu/dataset/228/sms+spam+collection`, 2011.

[2] Tiago A. Almeida, José María Gómez Hidalgo, and Akebo Yamakami. Contributions to the study of SMS spam filtering: New collection and results. In *Proceedings of the 11th ACM Symposium on Document Engineering*, pages 259–262, 2011.

[3] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

[4] Shih-Yang Liu, Chien-Yi Wang, Hongxu Yin, Pavlo Molchanov, Yu-Chiang Frank Wang, Kwang-Ting Cheng, and Min-Hung Chen. DoRA: Weight-decomposed low-rank adaptation. *arXiv preprint arXiv:2402.09353*, 2024.

[5] Adam Paszke et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[6] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 2019.

[7] Daniel Soudry, Elad Hoffer, Mor Shpigel Nacson, Suriya Gunasekar, and Nathan Srebro. The implicit bias of gradient descent on separable data. *Journal of Machine Learning Research*, 19(70):1–57, 2018.